Разработка устройства распознавания и декодирования радиосигналов с использованием методов машинного обучения.

Введение

Современные беспроводные системы связи характеризуются высокой плотностью передачи данных и разнообразием используемых радиосигналов. В этих условиях растёт потребность в эффективных методах автоматического распознавания и декодирования сигналов. Разработка устройств, способных идентифицировать тип модуляции и извлекать информацию из радиосигнала, имеет важное значение для коммерческих коммуникационных систем, а также для научных и военных приложений.

Основная цель данной работы – разработка алгоритмической модели (устройства) для автоматического распознавания типа модуляции радиосигналов с использованием адаптивного комбинированного подхода на основе методов машинного обучения.

Для достижения поставленной цели необходимо решить задачи.

Проанализировать существующие методы распознавания радиосигналов. Требуется провести обзор классических алгоритмов машинного обучения (SVM, Random Forest, KNN), основанных на извлечении признаков, и современных нейросетевых подходов (CNN, LSTM, ResNet, Transformer), работающих непосредственно с I/Q-данными.

Исследовать и подготовить датасет для обучения и тестирования. Необходимо выбрать открытый датасет (RadioML 2018), содержащий различные типы модуляций в широком диапазоне отношений сигнал/шум (SNR), и определить принципы его использования для обучения различных типов нейронных сетей.

Провести экспериментальное исследование и сравнение нейросетевых моделей классификации. Необходимо выполнить обучение и тестирование отдельных моделей (CNN, LSTM, ResNet, Transformer) на выбранном датасете. Следует проанализировать их точность в зависимости от уровня SNR, чтобы выявить сильные и слабые стороны каждой архитектуры.

Разработать комбинированный адаптивный алгоритм распознавания. На основе результатов экспериментов требуется предложить и реализовать гибридную модель, которая будет динамически выбирать оптимальный классификатор в зависимости от предварительно оценённого уровня сигнал/шум.

Разработать и обучить модель для предварительной оценки SNR. Требуется реализовать компактную сверточную нейронную сеть (CNN) для регрессии, способную оценивать уровень SNR входного сигнала, что является ключевым элементом для работы адаптивного алгоритма.

Провести экспериментальную оценку эффективности разработанного устройства. Необходимо выполнить комплексное тестирование полного алгоритма (оценка SNR + адаптивная классификация) на отдельной тестовой выборке данных, чтобы проанализировать итоговую точность распознавания и работоспособность системы.

Структура работы соответствует последовательности решения поставленных задач. В Главе 1 проводится анализ методов распознавания радиосигналов, включая основные виды модуляции, параметр SNR, классические алгоритмы и применение нейронных сетей (LSTM, CNN, ResNet, Transformer). Глава 2 содержит описание используемого датасета RadioML 2018, его формата и методов обработки, включая особенности обучения отдельных моделей и использования предобученных. Глава 3 посвящена экспериментальным исследованиям и результатам: постановке эксперимента и анализу работы одиночных нейросетевых моделей. В Главе 4 рассматривается разработка и тестирование комбинированной модели, а также проводится

сравнение с классическими алгоритмами. Глава 5 описывает процесс обучения модели для оценки SNR. В Главе 6 представлено итоговое устройство распознавания и приведены результаты его тестирования.

Ожидается, что данная работа продемонстрирует, как комбинация анализа сигнала, специализированных нейросетевых архитектур и адаптивной логики выбора позволяет создать эффективное решение для автоматического распознавания радиосигналов в условиях переменного качества канала связи.

ГЛАВА 1. АНАЛИЗ МЕТОДОВ РАСПОЗНАВАНИЯ РАДИОСИГНАЛОВ

1.1 Основные виды модуляции

Радиосигналы могут передавать информацию с использованием различных методов модуляции. Выбор типа модуляции зависит от требований к скорости передачи данных, устойчивости к шуму и спектральной эффективности. В работе рассматриваются 24 типа модуляции, включая как амплитудные, так и фазовые и частотные методы модуляции.

№	Обозначение	Полное название	Тип модуляции	Основной параметр	Краткое описание
1	OOK	On-Off Keying	Амплитудная (цифровая)	Амплитуда	Передача битов наличием или отсутствием несущей
2	4ASK	4-Level Amplitude Shift Keying	Амплитудная	Амплитуда	Четырёхуровневая амплитудная манипуляция
3	8ASK	8-Level Amplitude Shift Keying	Амплитудная	Амплитуда	Восьмиуровневая амплитудная манипуляция
4	BPSK	Binary Phase Shift Keying	Фазовая	Фаза	Два фазовых состояния (0°, 180°)
5	QPSK	Quadrature Phase Shift Keying	Фазовая	Фаза	Четыре фазовых состояния
6	8PSK	8-Phase Shift Keying	Фазовая	Фаза	Восемь фазовых состояний
7	16PSK	16-Phase Shift Keying	Фазовая	Фаза	Шестнадцать фазовых состояний
8	32PSK	32-Phase Shift Keying	Фазовая	Фаза	Высокая спектральная эффективность
9	16APSK	16-Amplitude Phase Shift Keying	Амплитудно-фазовая	Амплитуда + фаза	Комбинация фазовых и амплитудных уровней

10	32APSK	32-Amplitude Phase Shift Keying	Амплитудно-фазовая	Амплитуда + фаза	Используется в спутниковых системах
11	64APSK	64-Amplitude Phase Shift Keying	Амплитудно-фазовая	Амплитуда + фаза	Повышенная плотность созвездия
12	128APSK	128-Amplitude Phase Shift Keying	Амплитудно-фазовая	Амплитуда + фаза	Очень высокая спектральная эффективность
13	16QAM	16-Quadrature Amplitude Modulation	Квадратурная	Амплитуда + фаза	Широко используется в LTE, Wi-Fi
14	32QAM	32-Quadrature Amplitude Modulation	Квадратурная	Амплитуда + фаза	Компромисс между помехоустойчивостью и скоростью
15	64QAM	64-Quadrature Amplitude Modulation	Квадратурная	Амплитуда + фаза	Высокая пропускная способность
16	128QAM	128-Quadrature Amplitude Modulation	Квадратурная	Амплитуда + фаза	Требует высокого SNR
17	256QAM	256-Quadrature Amplitude Modulation	Квадратурная	Амплитуда + фаза	Очень высокая плотность созвездия
18	AM-SSB-WC	AM Single Sideband With Carrier	Амплитудная (аналоговая)	Амплитуда	Однополосная АМ с несущей
19	AM-SSB-SC	AM Single Sideband Suppressed Carrier	Амплитудная (аналоговая)	Амплитуда	Однополосная АМ без несущей
20	AM-DSB-WC	AM Double Sideband With Carrier	Амплитудная (аналоговая)	Амплитуда	Двухполосная АМ с несущей
21	AM-DSB-SC	AM Double Sideband Suppressed Carrier	Амплитудная (аналоговая)	Амплитуда	Двухполосная АМ без несущей
22	FM	Frequency Modulation	Частотная (аналоговая)	Частота	Информация кодируется изменением частоты
23	GMSK	Gaussian Minimum Shift Keying	Частотно-фазовая	Частота + фаза	Используется в GSM
24	OQPSK	Offset Quadrature Phase Shift Keying	Фазовая	Фаза	Смещённые I/Q компоненты уменьшают фазовые скачки

Таблица 1. Классы модуляции сигналов, используемые в эксперименте на основе датасета RadioML2018.

1.2 Отношение сигнал/шум (SNR)

SNR (Signal-to-Noise Ratio, отношение сигнал/шум) – это ключевой параметр в телекоммуникациях, характеризующий качество передаваемого

сигнала. Он показывает, насколько мощность полезного сигнала превышает уровень шума, присутствующего в канале.

$$SNR = 10\log_{10}(\frac{P_{signal}}{P_{noise}}) \text{ дБ}$$

Где P_{signal} – средняя мощность полезного сигнала, P_{noise} – средняя мощность шума.

Значение SNR:

Высокое значение SNR означает, что сигнал хорошо различим на фоне шума и алгоритмы распознавания работают точнее.

Низкое значение SNR затрудняет идентификацию модуляции и увеличивает вероятность ошибок.

В данной работе SNR используется как один из факторов, влияющих на точность распознавания сигналов. Анализ SNR помогает оценить надежность работы алгоритмов в условиях шумного канала.

1.3 Классические алгоритмы распознавания

Классические методы распознавания радиосигналов основываются на извлечении признаков из I/Q-компонент сигнала и последующем применении алгоритмов машинного обучения. Эти методы не используют сложные нейросетевые архитектуры, что делает их относительно простыми и интерпретируемыми.

Для обучения классических алгоритмов и нейросетей использовались одни и те же исходные радиосигналы I/Q из датасета RadioML2018. Разница заключается в подготовке данных: классические алгоритмы обучаются на векторах извлечённых признаков, тогда как нейросети получают сигнал почти в исходном виде и сами выделяют необходимые характеристики

1.3.1 Признаки сигналов

Для распознавания модуляции из радиосигналов часто используются следующие признаки:

Энергия сигнала – средняя мощность I/Q-компонент:

$$E = \frac{1}{N}\sum_{n=1}^{N}(I[n^2] + Q[n^2])$$

Статистические моменты – среднее, дисперсия I и Q-компонент.

Zero-Crossing Rate (ZCR) – количество пересечений сигнала через ноль, отражает частотные характеристики сигнала.

Спектральные признаки – амплитуды первых коэффициентов FFT для I и Q, показывают распределение энергии по частотам.

Эти признаки формируют вектор признаков, на основе которого алгоритмы классификации определяют тип модуляции.

1.3.2 Обучаемые классические алгоритмы

В данной работе использовались обучаемые классические методы, которые способны различать все 24 типа модуляции, в отличие от простых эвристических методов, которые недостаточно точны для полного набора классов:

SVM (Support Vector Machine)

Использует ядро RBF для разделения классов в высокоразмерном пространстве признаков. Подходит для задач с множеством классов и небольшим числом признаков.

Random Forest

Ансамбль решающих деревьев, который голосует за наиболее вероятный класс. Устойчив к шуму и переобучению, хорошо работает с дискретными и непрерывными признаками.

K-Nearest Neighbors (KNN)

Относит сигнал к классу, к которому ближе всего k соседей в признаковом пространстве. Прост в реализации и интерпретации, чувствителен к масштабированию признаков. В работе использовался предварительный StandardScaler для нормализации признаков, что улучшает работу SVM и KNN.

1.4 Применение нейронных сетей

Нейросетевые подходы позволяют напрямую работать с сигналом I/Q без необходимости ручного извлечения признаков, что дает возможность выявлять более сложные зависимости и повышать точность распознавания.

В рамках данной работы используются следующие типы нейронных сетей:

CNN (Convolutional Neural Network) – сверточная нейронная сеть;

LSTM (Long Short-Term Memory) – рекуррентная нейронная сеть с механизмом долговременной памяти;

ResNet (Residual Neural Network) – разновидность глубокой сверточной нейронной сети с остаточными связями;

Transformer – архитектура нейронной сети, основанная на механизме самовнимания (self-attention).

Все перечисленные архитектуры принимают на вход последовательности комплексных отсчётов радиосигнала в виде пар (I, Q) и выполняют автоматическое извлечение информативных признаков, необходимых для задачи классификации модуляции.

Сверточные нейронные сети применяются для выявления локальных временных и структурных особенностей сигнала, рекуррентные модели ориентированы на анализ временной динамики, а архитектуры с механизмом самовнимания позволяют учитывать взаимосвязи между отсчётами сигнала на всей временной последовательности.

1.4.1 LSTM

Модель LSTM применяется для анализа временной структуры сигнала. На вход подается последовательность I/Q-сигнала. В работе использовалась LSTM, обученная на сигналах с SNR > 8 дБ.

Архитектура модели LSTM:

№	Слои	Примечания
1	LSTM	Извлекает временные зависимости в сигнале. Bidirectional учитывает контекст слева и справа.
2	fc1 + BatchNorm1d + Dropout	Сжимает и нормализует признаки LSTM, регуляризация через Dropout.
3	fc2 + BatchNorm1d + Dropout	Дополнительная обработка признаков, предотвращение переобучения.
4	fc3	Финальный классификатор, выдаёт вероятности для 24 типов модуляций.

Обработка последовательностей по времени: LSTM хорошо запоминает предыдущие состояния и извлекает временные зависимости. Двухнаправленный LSTM (bidirectional=True) позволяет учитывать как прошлое, так и будущее в последовательности. Dropout и BatchNorm используются для регуляризации и стабильного обучения.

1.4.2 CNN

CNN применяются для извлечения пространственных и спектральных признаков из I/Q-сигнала.

Архитектура CNN (пример):

№	Слои	Примечания
1	Conv Block 1 (conv1–conv3 + pool1)	Извлечение базовых локальных признаков и уменьшение размерности последовательности. Skip connection сохраняет исходную информацию.
2	Conv Block 2 (conv4–conv6 + pool2)	Углубление признаков, сохранение информации через skip connection, понижение размерности.
3	Conv Block 3 (conv7–conv9 + pool3)	Извлечение более сложных признаков, уменьшение длины последовательности.
4	Conv Block 4 (conv10–conv12 + pool4)	Углубление и уточнение признаков, сокращение размерности для компактного представления.

5	Conv Block 5 (conv13–conv15 + pool5)	Финальное извлечение признаков, сохранение информации через skip connection, подготовка к fully connected.
6	Flatten	Преобразование 3D-тензора в 2D для подачи на полносвязные слои.
7	Fully Connected (fc1 + Dropout1 + fc2 + Dropout2 + fc3)	Сжатие признаков в компактное пространство, регуляризация, финальный классификатор на 24 класса.

Слой Conv1D извлекает локальные паттерны в сигнале. Residual connections позволяют строить более глубокие сети без деградации градиента. Pooling уменьшает размерность, сохраняя ключевые признаки. Полносвязные слои после свёрток с Dropout обеспечивают регуляризацию и сжатие признаков перед классификацией.

1.4.3 ResNet

ResNet – это глубокая CNN с остаточными (residual) связями, предотвращающими затухание градиентов при глубоком обучении. Использовалась предобученная модель из проекта “Enhanced Low SNR Radio Signal Classification using Deep Learning”.

№	Слои	Примечания
1	Input + Reshape	Преобразование сигнала в “2D-формат” для ResNet.
2	Initial Conv2D 7x7 + BN + ReLU + MaxPool	Первичная обработка сигнала: извлечение базовых признаков, уменьшение размерности.
3	ResNet Stage 1 (residual_block ×2, filters=64)	Сохраняет исходные признаки через skip connections; извлекает низкоуровневые особенности.
4	ResNet Stage 2 (residual_block ×2, filters=128, stride=2)	Среднеуровневые признаки; stride=2 уменьшает пространственную размерность.
5	ResNet Stage 3 (residual_block ×2, filters=256, stride=2)	Глубокие признаки с увеличением каналов.
6	ResNet Stage 4 (residual_block ×2, filters=512, stride=2)	Очень глубокие признаки с широкой репрезентацией.
7	GlobalAveragePooling2D + BN + Dropout	Сжатие признаков в вектор фиксированной размерности, регуляризация.
8	Dense 512 → BN → Dropout → Dense 256 → BN → Dropout	Полносвязные слои для компрессии и стабилизации признаков.
9	Dense 24 + softmax	Финальный классификатор.

Residual connections позволяют строить очень глубокие сети без проблем затухания градиента. Эффективно извлекает локальные и средние пространственные признаки. Подходит для “сигналов как картинок” (с преобразованием 2D), хорошо работает с шумными сигналами.

1.4.4 Transformer

Модель Transformer использует механизм внимания (self-attention) для анализа последовательностей сигналов. На вход подается последовательность I/Q. Предобученная модель из проекта “Enhanced Low SNR Radio Signal Classification using Deep Learning” использовалась без изменения исходных весов.

№	Слои	Примечания
1	Input + Reshape	Преобразует сигнал для подачи в Transformer.
2	MultiHeadSelfAttention (num_heads=128, embed_dim=1024)	Захватывает глобальные зависимости между временными шагами; внимание позволяет сети концентрироваться на важных частях сигнала.
3	TransformerBlock (MHA + FFN + LayerNorm + Dropout)	Углубленная обработка признаков, residual connections + нормализация + регуляризация Dropout.
4	GlobalAveragePooling1D	Сжимает временную ось, агрегируя признаки, уменьшает размерность перед FC.
5	BatchNormalization + AlphaDropout	Стабилизация обучения и регуляризация для selu-активаций.
6	Dense 128 → AlphaDropout → Dense 128 → AlphaDropout	Полносвязные слои для сжатия признаков и регуляризации.
7	Dense 24 + softmax	Финальный классификатор: вероятности для 24 классов модуляции.

Использует self-attention, что позволяет учитывать глобальные зависимости сигнала. Residual + LayerNorm + AlphaDropout повышают устойчивость к переобучению и стабильность обучения. Эффективнее для длинных сигналов, чем простые LSTM, т.к. внимание масштабируется на всю последовательность.

ГЛАВА 2. ОПИСАНИЕ ДАТАСЕТА И МЕТОДОВ ОБРАБОТКИ

2.1 Используемый датасет RadioML 2018

В качестве основного набора данных в данной работе используется открытый датасет RadioML 2018 (RadioML 2018.01A), предназначенный для исследований в области автоматического распознавания модуляции радиосигналов с применением методов машинного обучения и нейронных сетей.

Датасет RadioML 2018 представляет собой синтетически сгенерированный набор радиосигналов, сформированных в формате комплексных отсчётов I/Q. Каждый сигнал описывается двумя компонентами:

I (In-phase) – действительная составляющая,

Q (Quadrature) – мнимая составляющая.

Сигналы представлены в виде последовательностей фиксированной длины 1024 отсчёта, что позволяет использовать датасет как для сверточных, так и для рекуррентных и трансформерных нейросетевых архитектур.

2.1.1 Набор модуляций

Датасет содержит 24 типа модуляции, включающие как цифровые, так и аналоговые методы передачи информации. В их число входят:

Наличие широкого набора модуляций различной сложности делает датасет репрезентативным для оценки качества алгоритмов автоматического распознавания сигналов в реальных условиях.

2.1.2 Диапазон значений SNR

Сигналы в датасете RadioML 2018 представлены при различных значениях отношения сигнал/шум (SNR, Signal-to-Noise Ratio).

Диапазон SNR охватывает значения от −20 дБ до +30 дБ с фиксированным шагом, что позволяет анализировать работу моделей как в условиях сильного шума, так и при практически идеальном качестве канала.

Каждый сигнал в датасете однозначно маркируется: типом модуляции, значением SNR. Это даёт возможность проводить анализ точности распознавания моделей в зависимости от уровня шума и исследовать устойчивость алгоритмов к искажениям канала.

2.2 Формат и представление данных

Каждый пример в датасете представляет собой тензор размерности: 1024×2, где 1024 – количество временных отсчётов сигнала, 2 – число каналов (I и Q).

Такое представление данных делает возможным использование различных типов нейронных сетей. Сверточные модели (CNN и ResNet) применяются после изменения формы входного тензора, рекуррентные сети LSTM принимают сигнал напрямую в виде временной последовательности, а модели типа Transformer рассматривают сигнал как последовательность отсчётов для анализа долгосрочных зависимостей.

При этом перед подачей данных в нейросети не выполнялось ручное извлечение признаков. Это позволяет моделям самостоятельно обучаться выявлению наиболее информативных характеристик сигнала непосредственно из исходных I/Q-данных.

2.3 Использование датасета при обучении моделей

В рамках данной работы датасет RadioML 2018 использовался различным образом для разных нейросетевых архитектур.

2.3.1 Обучение моделей CNN и LSTM

Сверточные нейронные сети (CNN) и рекуррентные нейронные сети LSTM были обучены на датасете RadioML 2018. В ходе экспериментов рассматривались различные диапазоны отношения сигнал/шум (SNR): 6, 8, 10 и 16 дБ.

Выбор данных значений SNR обусловлен особенностями качества принимаемого радиосигнала. При уровне 6 дБ сигнал уже содержит различимую полезную информацию, однако влияние шума остается заметным. При 8 дБ вклад шума существенно снижается, и сигнал можно рассматривать как относительно чистый. Значение 10 дБ соответствует условиям, при которых влияние шума на форму сигнала минимально. При 16 дБ сигнал практически не искажается шумом и может рассматриваться как близкий к идеальному.

Целью эксперимента являлось определение такого диапазона значений отношения сигнал/шум (SNR), при обучении на котором модели демонстрируют наибольшую точность классификации при проверке на общей тестовой выборке.

Для оценки качества классификации использовалась единая тестовая выборка объёмом 50 000 примеров. В зависимости от выбранного диапазона SNR обучающая выборка формировалась путём случайного отбора 50 000 сигналов, значения SNR которых находились в пределах заданного интервала.

Например, при выборе диапазона от 6 дБ до 30 дБ в обучающую выборку включались случайно отобранные примеры сигналов с уровнями SNR, лежащими в указанном интервале.

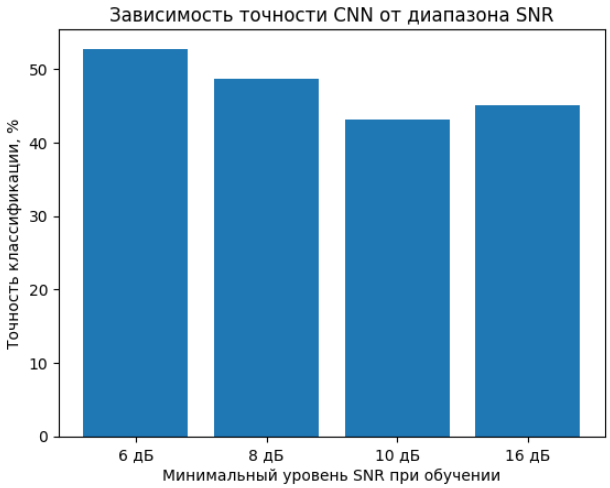

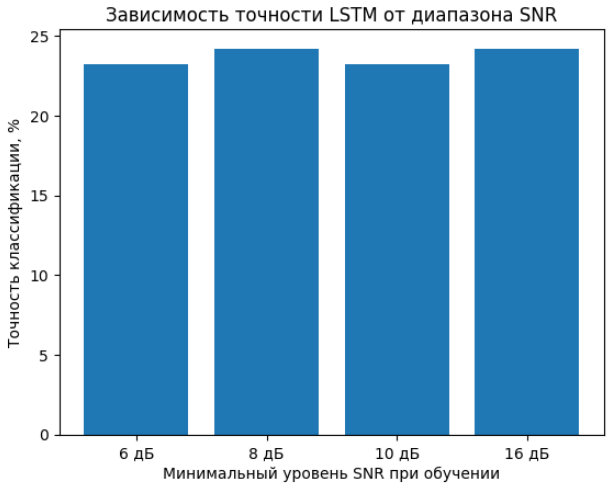

По результатам проведённых экспериментов можно сделать вывод, что сверточная нейронная сеть (CNN) демонстрирует более простое и быстрое обучение по сравнению с моделью LSTM. Это связано с меньшей сложностью архитектуры и меньшим числом обучаемых параметров. Наилучшие результаты CNN достигаются при обучении на более широком диапазоне значений SNR, что свидетельствует о её способности эффективно обобщать информацию при наличии сигналов различного качества.

Модель LSTM, в свою очередь, обладает более сложной архитектурой, ориентированной на анализ временных зависимостей сигнала. Вследствие этого она требует большего объёма данных и более длительного времени обучения для достижения высокой точности. Несмотря на то, что в рамках данных экспериментов точность LSTM оказалась ниже, в более благоприятных условиях и при увеличении обучающей выборки данная модель потенциально превосходит CNN по качеству классификации.

Дополнительным практическим фактором является размер модели: файл весов CNN занимает около 1 МБ, тогда как размер весов LSTM составляет порядка 7 МБ. Это делает CNN более предпочтительной для использования в системах с ограниченными вычислительными ресурсами или требованиями к памяти, тогда как LSTM целесообразно применять в задачах, где приоритетом является максимальная точность, а ресурсы не являются критичным ограничением.

Таким образом, для обучения моделей была использована выборка сигналов с уровнем SNR выше 8 дБ, что позволило достичь оптимального компромисса между скоростью обучения и качеством распознавания. Модель CNN применялась к этой выборке для эффективного извлечения пространственных признаков, а LSTM – для обучения на временных зависимостях сигналов.

2.3.2 Использование предобученных моделей ResNet и Transformer

Архитектуры ResNet и Transformer были заимствованы из открытого проекта: *Final Project for AI Wireless 2020 in National Chiao Tung University (NCTU), Fall 2020*

Для адаптации предобученных моделей к условиям датасета RadioML 2018 было выполнено их дообучение на используемом наборе данных.

В результате дообучения Resnet было зафиксировано увеличение точности распознавания по сравнению с исходными весами.

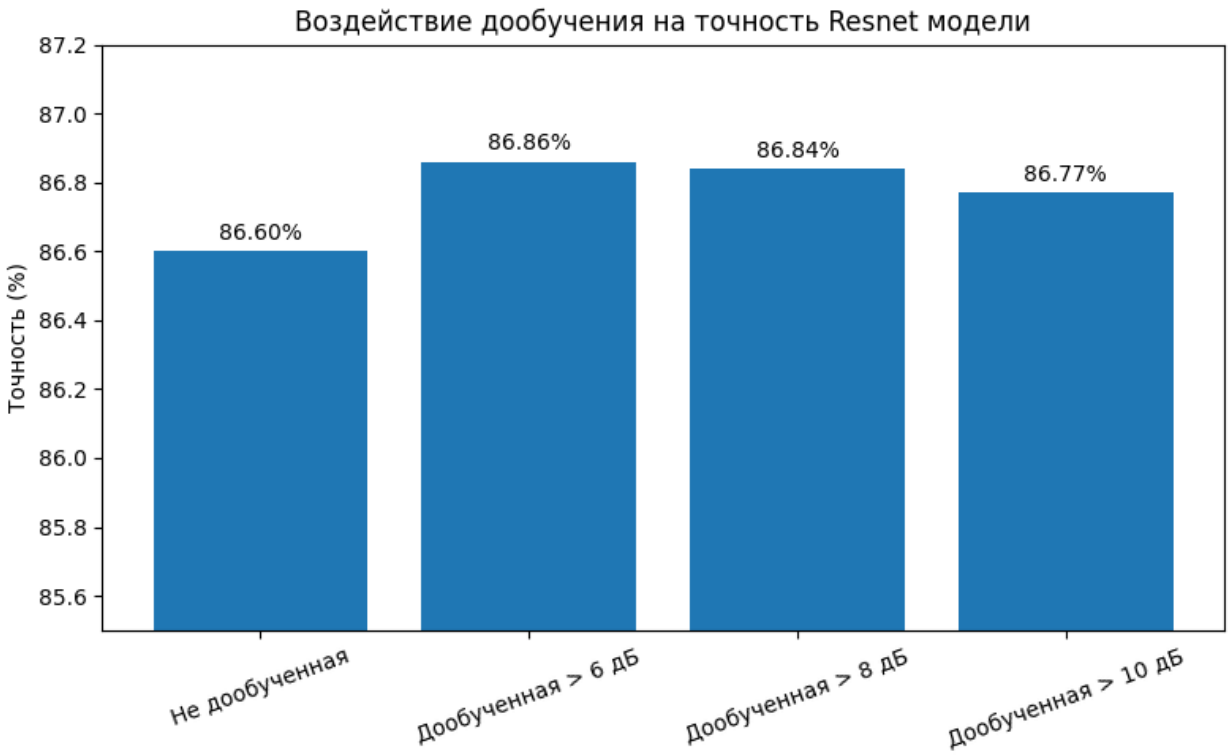

Следует отметить, что величина прироста качества может зависеть от используемого датасета, диапазона SNR и архитектурных особенностей модели. Тем не менее, полученный результат подтверждает целесообразность адаптации предобученных моделей под конкретную задачу.

При этом файлы моделей ResNet и Transformer занимают соответственно 10 МБ и 57 МБ.

ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНЫЕ ИССЛЕДОВАНИЯ И РЕЗУЛЬТАТЫ

3.1 Постановка эксперимента

В рамках данной главы проводится экспериментальное исследование эффективности различных нейросетевых моделей для задачи автоматического распознавания типов цифровой и аналоговой модуляции радиосигналов.

Эксперименты выполнялись с использованием датасета RadioML2018, содержащего комплексные I/Q-сигналы, и охватывали несколько архитектур нейронных сетей, различающихся по принципам обработки временной и спектральной информации.

3.2 Эксперименты с одиночными нейросетевыми моделями

В данном разделе представлены результаты работы отдельных нейросетевых моделей.

Для тестовой выборки, от -20 дБ до 30 дБ с 102237 сигналов, была дополнительно построена матрица ошибок, которая позволила оценить качество распознавания по каждому классу модуляции.

3.2.1 Сверточная нейронная сеть (CNN)

Сверточная нейронная сеть (CNN) использует одномерные сверточные слои с остаточными соединениями, что позволяет эффективно извлекать локальные временные и спектральные признаки радиосигнала.

На основе проведённых экспериментов был построен рисунок:

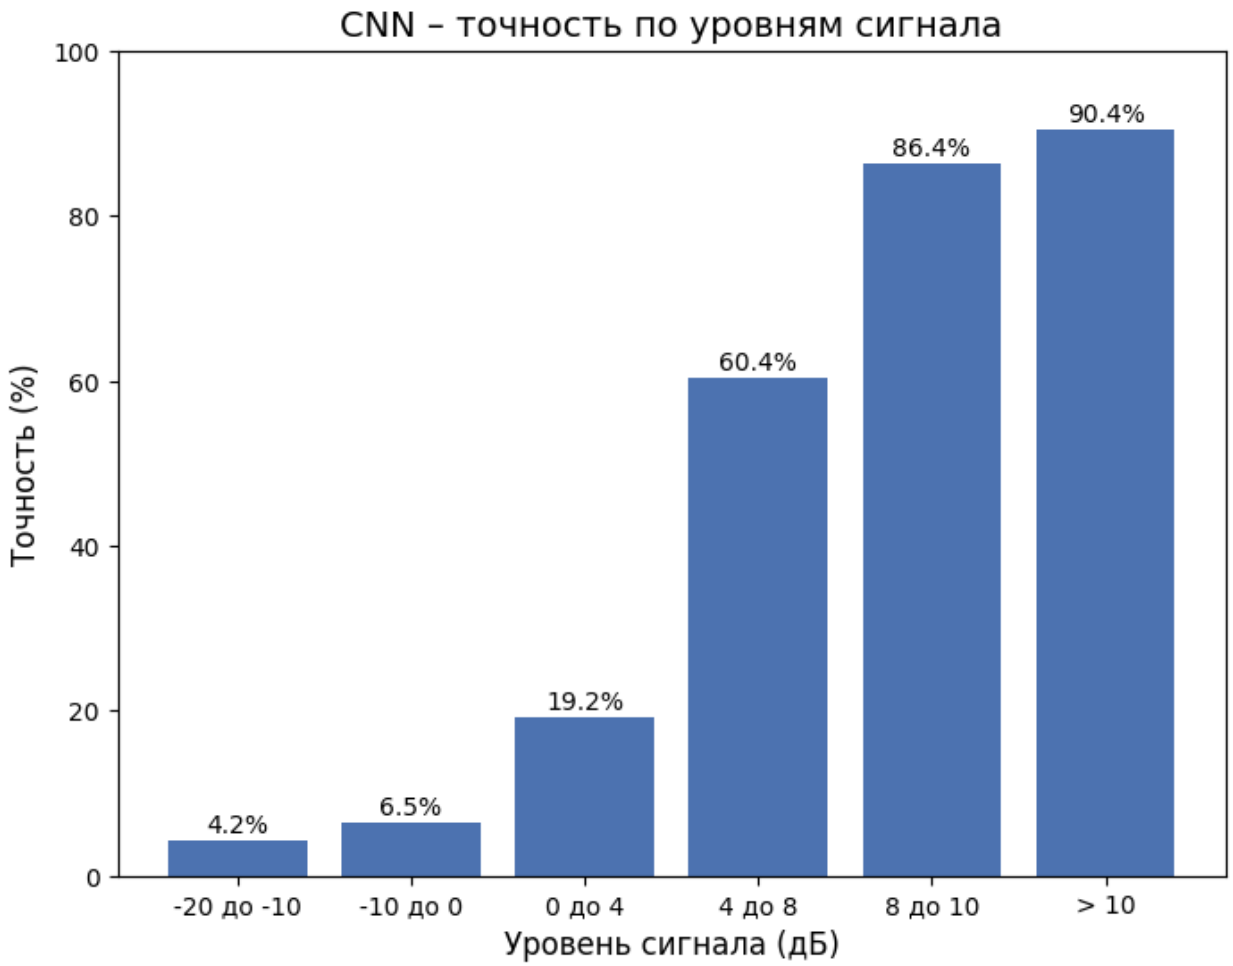

Анализ полученных данных показывает, что CNN демонстрирует наивысшую точность классификации при высоких уровнях SNR, превышающих 10 дБ.

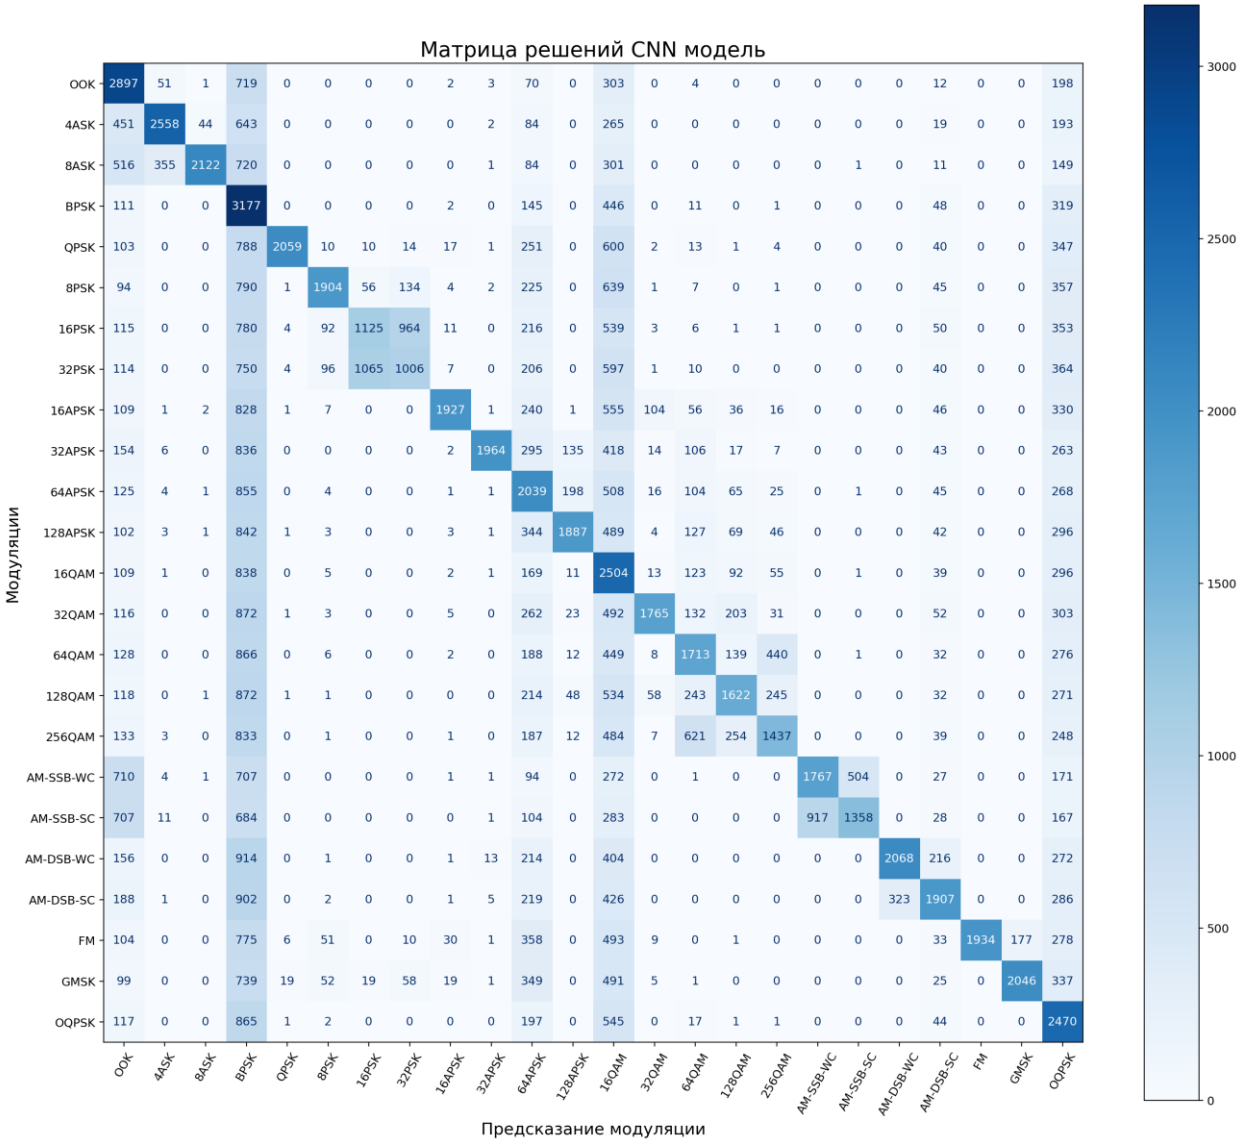

Общая точность модели 46.22%

3.2.2 Рекуррентная нейронная сеть LSTM

Модель на основе двунаправленной LSTM предназначена для анализа временной структуры радиосигнала и выявления долгосрочных зависимостей между отсчётами.

Результаты экспериментов по точности классификации в зависимости от уровня сигнала (SNR) представлены на рисунке:

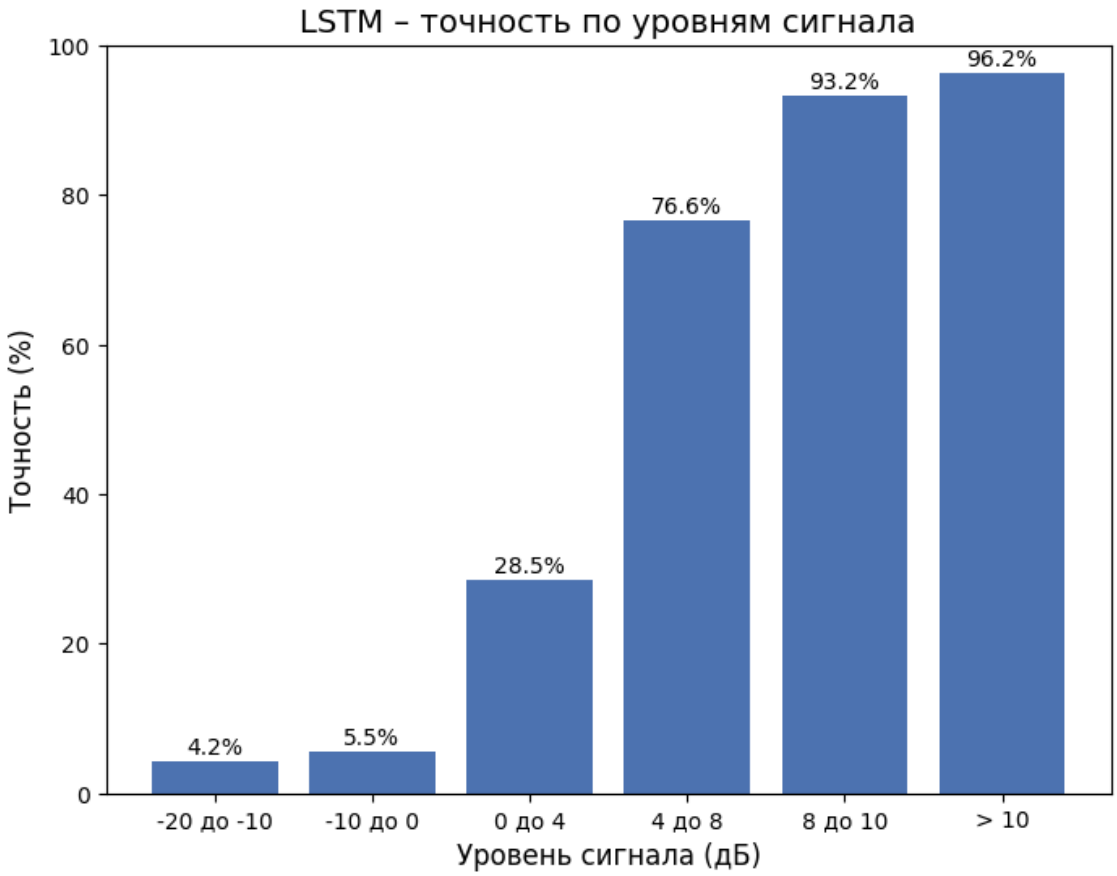

Анализ данных показывает, что модель LSTM достигает наивысшей точности при высоких уровнях SNR, превышающих 10 дБ. Была построена матрица ошибок, позволяющая оценить качество, распознавания по каждому классу модуляции.

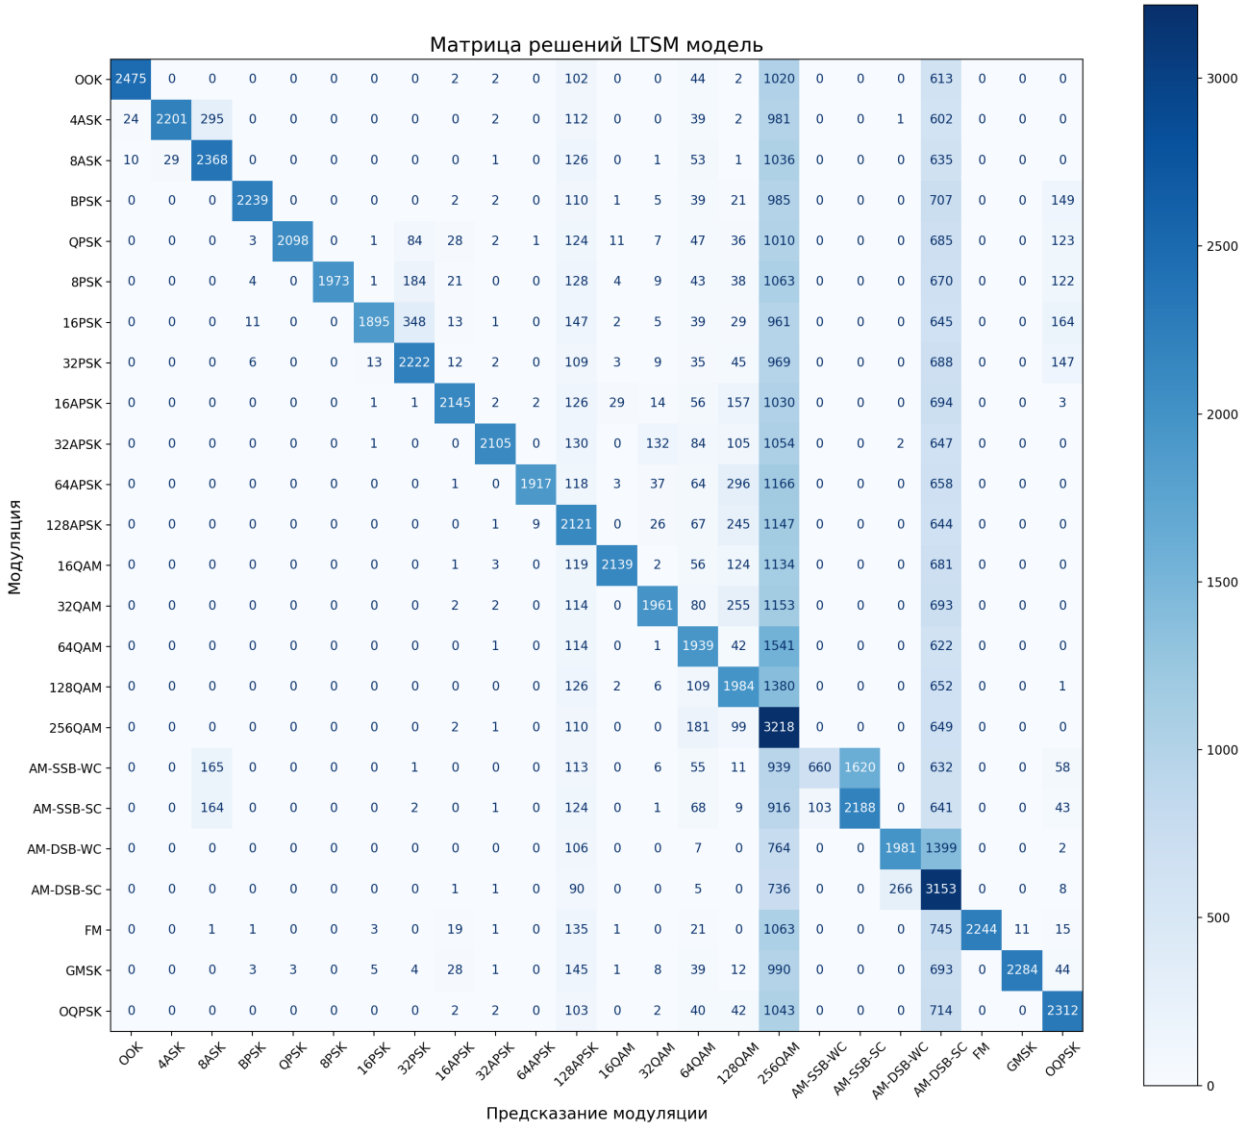

Общая точность модели 50.69%

3.2.3 Глубокая сверточная сеть ResNet

Модель ResNet основана на использовании остаточных блоков, что позволяет строить более глубокие нейронные сети без деградации качества обучения. Такая архитектура эффективно извлекает устойчивые признаки радиосигнала, даже в условиях шумного сигнала.

Результаты классификации в зависимости от уровня сигнала (SNR) представлены на рисунке:

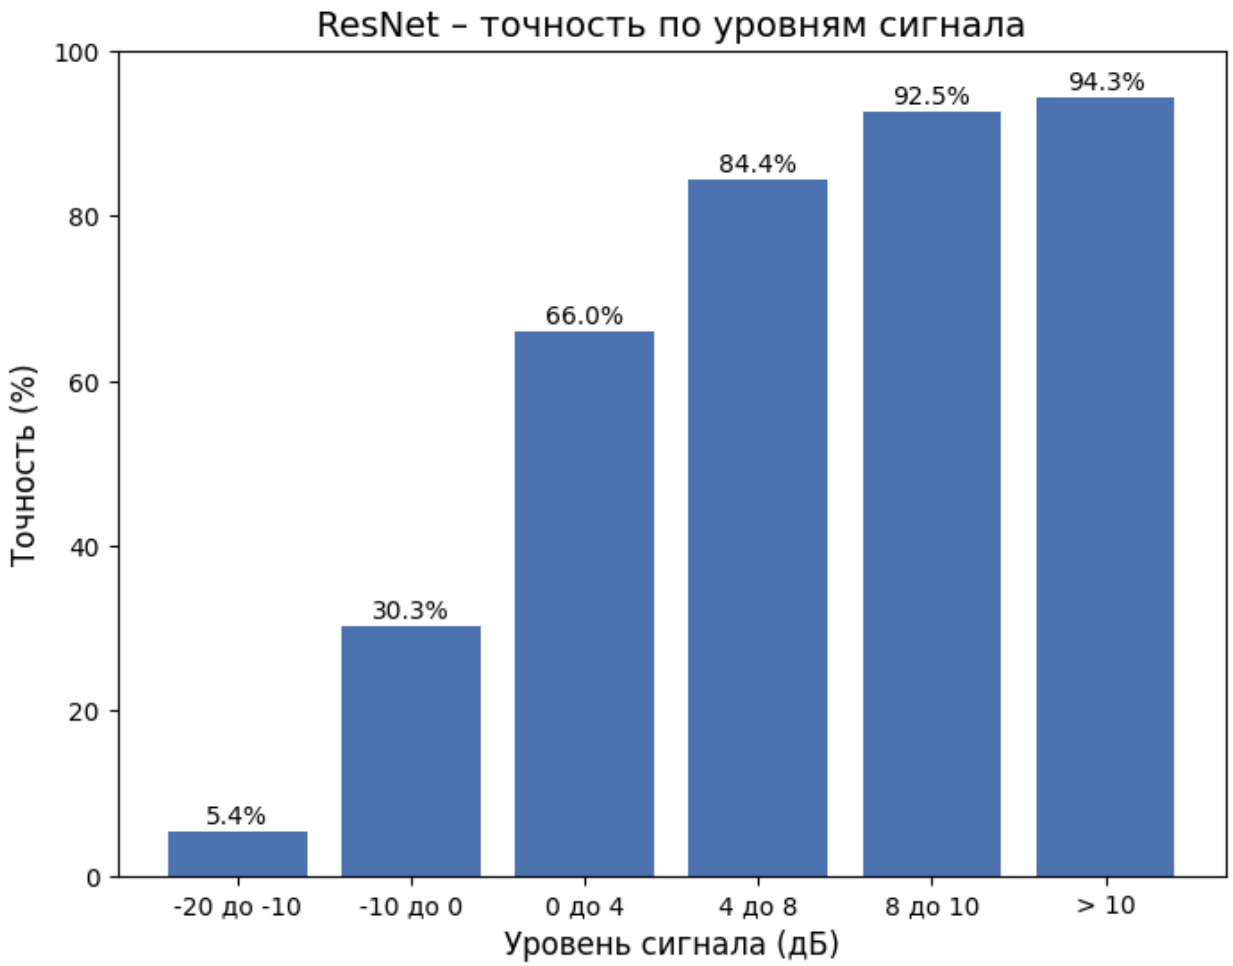

Анализ таблицы показывает, что ResNet достигает наивысшей точности при высоких уровнях SNR, превышающих 10 дБ. Для данного диапазона была построена матрица ошибок, демонстрирующая эффективность модели по каждому классу модуляции.

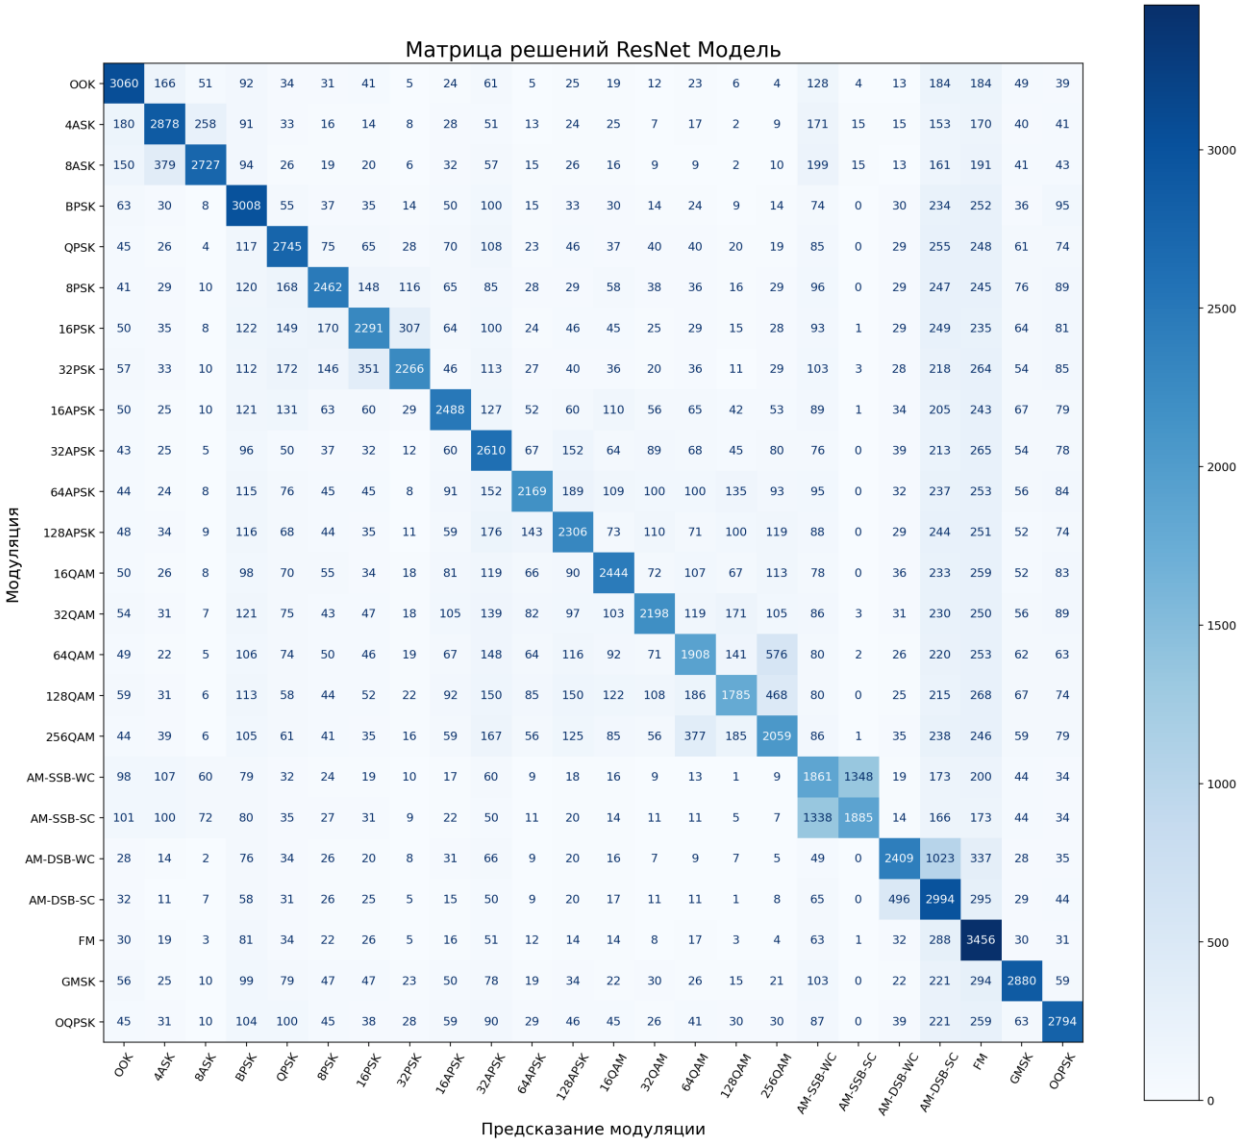

Общая точность модели 58.38%

3.2.4 Модель на основе Transformer

Модель Transformer использует механизм многоголового самовнимания (Multi-Head Self-Attention), который позволяет учитывать глобальные зависимости между отсчетами сигнала без применения рекуррентных слоев. Такая архитектура эффективно моделирует взаимосвязи на больших временных интервалах, что особенно важно для сложных радиосигналов.

Результаты классификации в зависимости от уровня сигнала (SNR) представлены на рисунке:

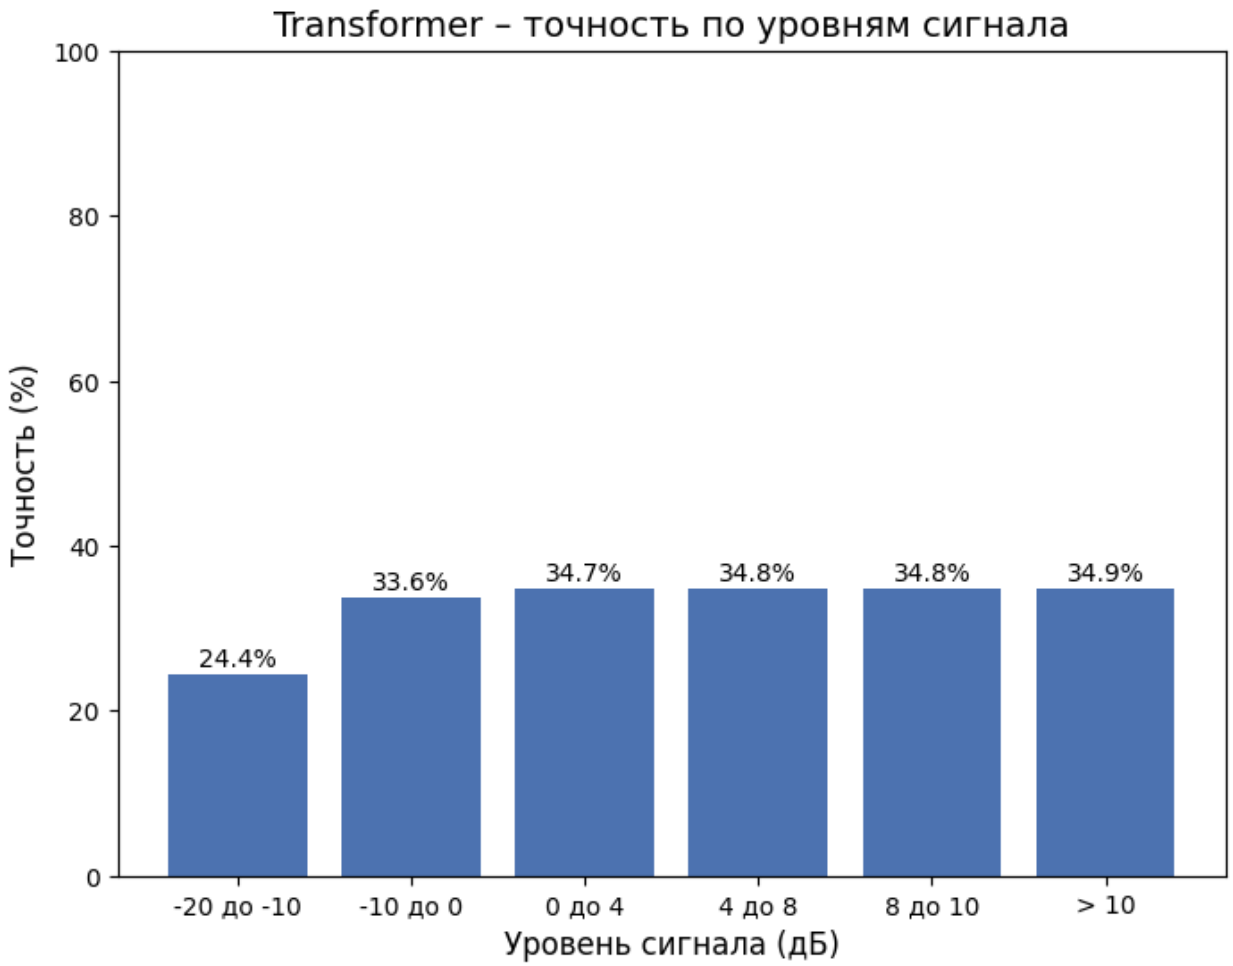

Анализ таблицы показывает, что Transformer демонстрирует стабильные результаты даже при низких значениях SNR и достигает максимальной точности при высоких уровнях сигнала, превышающих 10 дБ. Для этого диапазона была построена матрица ошибок, которая иллюстрирует эффективность модели по каждому классу модуляции.

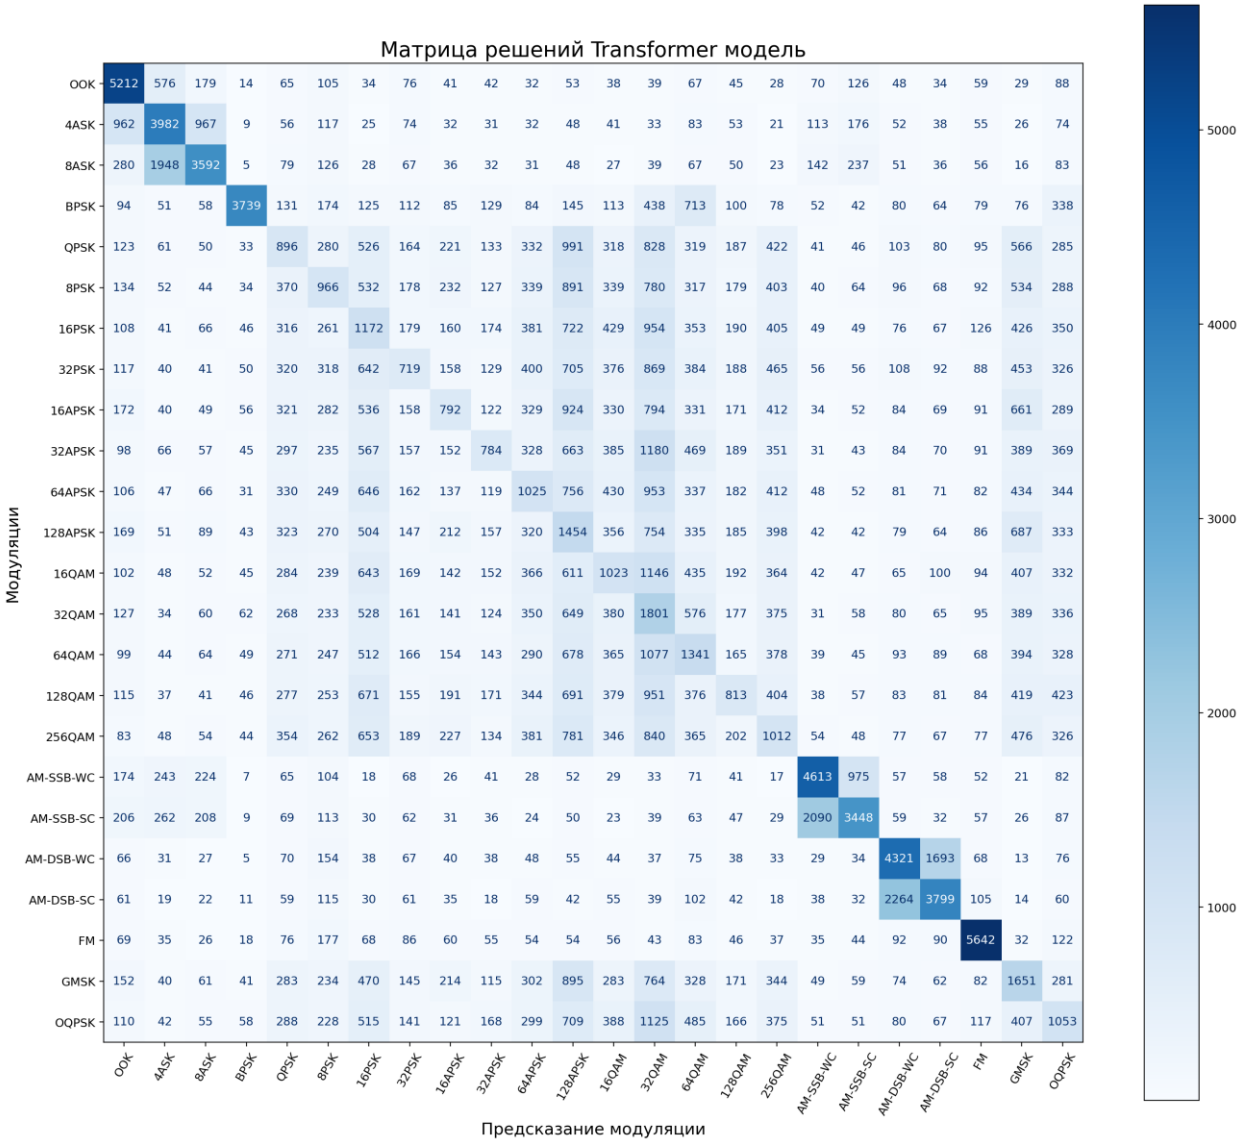

Общая точность модели 32.19%

3.3 Комбинированная модель

На основе проведенных экспериментов было решено разработать комбинированную модель, которая объединяет сильные стороны отдельных нейросетевых архитектур. CNN была исключена из комбинации, поскольку показала наименее конкурентоспособные результаты.

Для низкого уровня сигнала, от -20 до 0 дБ, использовалась модель Transformer, демонстрирующая высокую стабильность при низком SNR.

Для среднего диапазона, от 0 до 8 дБ, была выбрана ResNet, обеспечивающая эффективное извлечение устойчивых признаков и высокую точность при умеренных уровнях сигнала.

Для высокого уровня сигнала, от 8 дБ и выше, применялась двунаправленная LSTM, показавшая наилучшую способность выявлять долгосрочные зависимости и достигать максимальной точности при высоком SNR.

Выбор каждой модели был основан на результатах тестирования и соответствовал диапазону сигналов, где данная архитектура показывала наилучшие показатели.

Такое комбинированное решение позволило достичь наивысшей общей точности классификации на тестовой выборке.

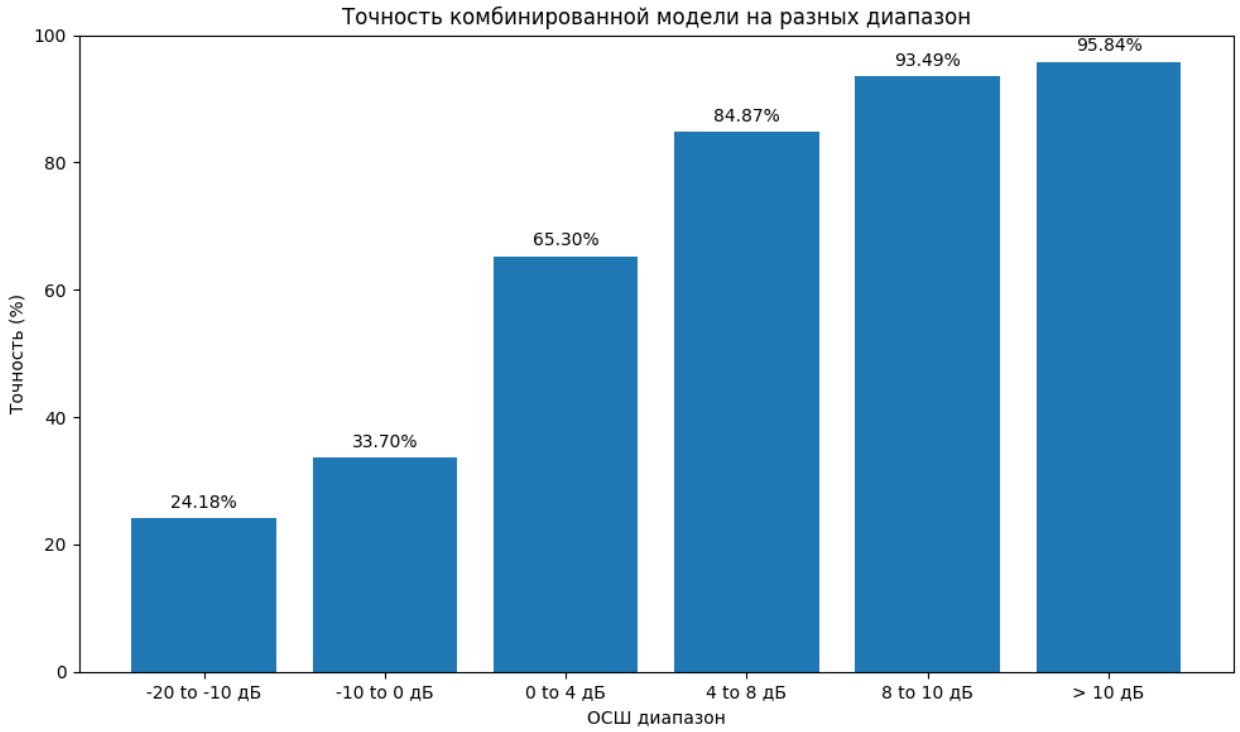

Результаты показывают, что разделение обработки сигналов по диапазонам SNR с использованием специализированных моделей позволяет значительно повысить точность классификации по сравнению с отдельными архитектурами.

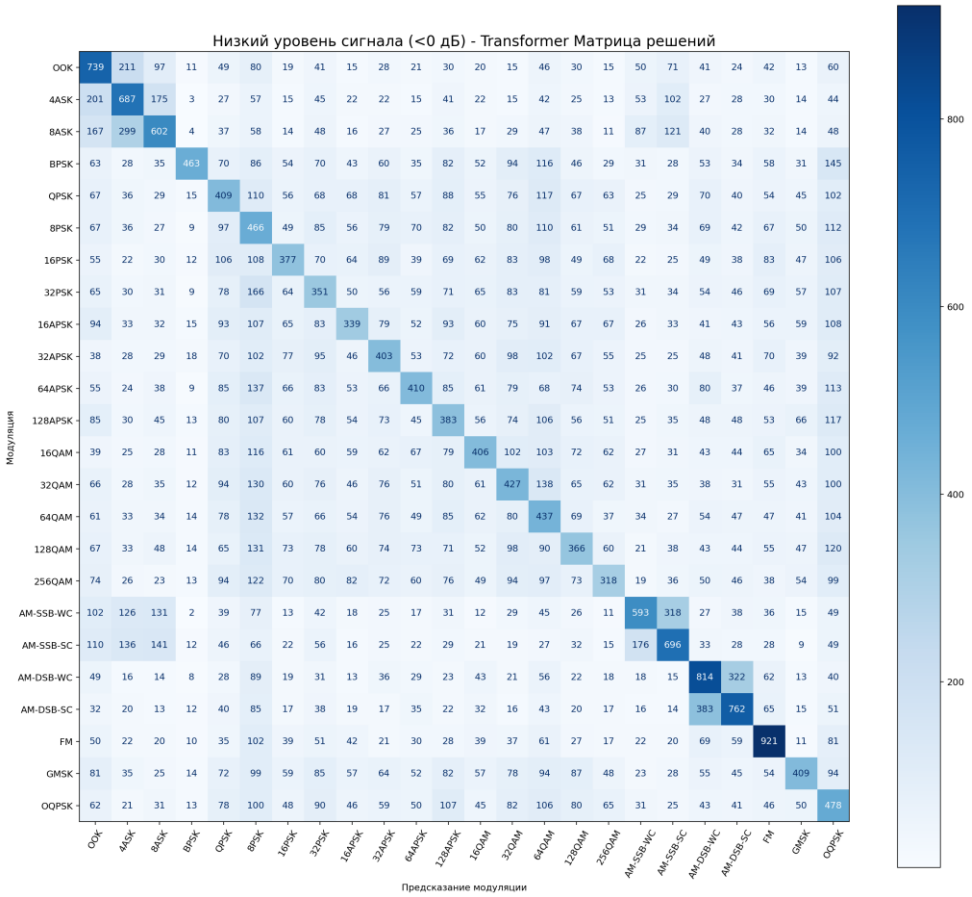
Низкий уровень сигнала (<0 дБ) - Transformer Матрица решений
Модуляция
Предсказание модуляции
OOK 739 211 97 11 49 80 19 41 15 28 21 30 20 15 46 30 15 50 71 41 24 42 13 60
4ASK 201 687 175 3 27 57 15 45 22 22 15 41 22 15 42 25 13 53 102 27 28 30 14 44
8ASK 167 299 602 4 37 58 14 48 16 27 25 36 17 29 47 38 11 87 121 40 28 32 14 48
BPSK 63 28 35 463 70 86 54 70 43 60 35 82 52 94 116 46 29 31 28 53 34 58 31 145
QPSK 67 36 29 15 409 110 56 68 68 81 57 88 55 76 117 67 63 25 29 70 40 54 45 102
8PSK 67 36 27 9 97 466 49 85 56 79 70 82 50 80 110 61 51 29 34 69 42 67 50 112
16PSK 55 22 30 12 106 108 377 70 64 89 39 69 62 83 98 49 68 22 25 49 38 83 47 106
32PSK 65 30 31 9 78 166 64 351 50 56 59 71 65 83 81 59 53 31 34 54 46 69 57 107
16APSK 94 33 32 15 93 107 65 83 339 79 52 93 60 75 91 67 67 26 33 41 43 56 59 108
32APSK 38 28 29 18 70 102 77 95 46 403 53 72 60 98 102 67 55 25 25 48 41 70 39 92
64APSK 55 24 38 9 85 137 66 83 53 66 410 85 61 79 68 74 53 26 30 80 37 46 39 113
128APSK 85 30 45 13 80 107 60 78 54 73 45 383 56 74 106 56 51 25 35 48 48 53 66 117
16QAM 39 25 28 11 83 116 61 60 59 62 67 79 406 102 103 72 62 27 31 43 44 65 34 100
32QAM 66 28 35 12 94 130 60 76 46 76 51 80 61 427 138 65 62 31 35 38 31 55 43 100
64QAM 61 33 34 14 78 132 57 66 54 76 49 85 62 80 437 69 37 34 27 54 47 47 41 104
128QAM 67 33 48 14 65 131 73 78 60 74 73 71 52 98 90 366 60 21 38 43 44 55 47 120
256QAM 74 26 23 13 94 122 70 80 82 72 60 76 49 94 97 73 318 19 36 50 46 38 54 99
AM-SSB-WC 102 126 131 2 39 77 13 42 18 25 17 31 12 29 45 26 11 593 318 27 38 36 15 49
AM-SSB-SC 110 136 141 12 46 66 22 56 16 25 22 29 21 19 27 32 15 176 696 33 28 28 9 49
AM-DSB-WC 49 16 14 8 28 89 19 31 13 36 29 23 43 21 56 22 18 18 15 814 322 62 13 40
AM-DSB-SC 32 20 13 12 40 85 17 38 19 17 35 22 32 16 43 20 17 16 14 383 762 65 15 51
FM 50 22 20 10 35 102 39 51 42 21 30 28 39 37 61 27 17 22 20 69 59 921 11 81
GMSK 81 35 25 14 72 99 59 85 57 64 52 82 57 78 94 87 48 23 28 55 45 54 409 94
OQPSK 62 21 31 13 78 100 48 90 46 59 50 107 45 82 106 80 65 31 25 43 41 46 50 478
OOK 4ASK 8ASK BPSK QPSK 8PSK 16PSK 32PSK 16APSK 32APSK 64APSK 128APSK 16QAM 32QAM 64QAM 128QAM 256QAM AM-SSB-WC AM-SSB-SC AM-DSB-WC AM-DSB-SC FM GMSK OQPSK
800
600
400
200

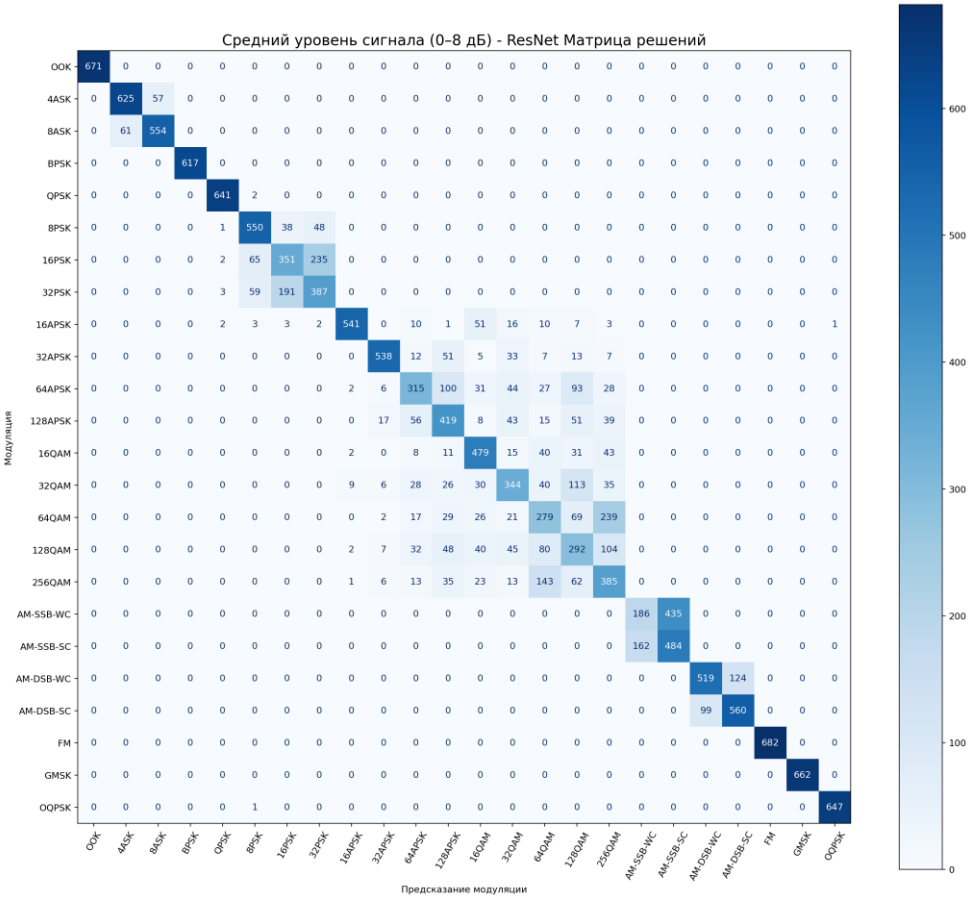
Средний уровень сигнала (0–8 дБ) - ResNet Матрица решений
Модуляция
Предсказание модуляции
OOK 671 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
4ASK 0 625 57 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
8ASK 0 61 554 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
BPSK 0 0 0 617 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
QPSK 0 0 0 0 641 2 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
8PSK 0 0 0 0 1 550 38 48 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
16PSK 0 0 0 0 2 65 351 235 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
32PSK 0 0 0 0 3 59 191 387 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
16APSK 0 0 0 0 2 3 3 2 541 0 10 1 51 16 10 7 3 0 0 0 0 0 0 1
32APSK 0 0 0 0 0 0 0 0 0 538 12 51 5 33 7 13 7 0 0 0 0 0 0 0
64APSK 0 0 0 0 0 0 0 0 2 6 315 100 31 44 27 93 28 0 0 0 0 0 0 0
128APSK 0 0 0 0 0 0 0 0 0 17 56 419 8 43 15 51 39 0 0 0 0 0 0 0
16QAM 0 0 0 0 0 0 0 0 2 0 8 11 479 15 40 31 43 0 0 0 0 0 0 0
32QAM 0 0 0 0 0 0 0 0 9 6 28 26 30 344 40 113 35 0 0 0 0 0 0 0
64QAM 0 0 0 0 0 0 0 0 0 2 17 29 26 21 279 69 239 0 0 0 0 0 0 0
128QAM 0 0 0 0 0 0 0 0 2 7 32 48 40 45 80 292 104 0 0 0 0 0 0 0
256QAM 0 0 0 0 0 0 0 0 1 6 13 35 23 13 143 62 385 0 0 0 0 0 0 0
AM-SSB-WC 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 186 435 0 0 0 0 0
AM-SSB-SC 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 162 484 0 0 0 0 0
AM-DSB-WC 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 519 124 0 0 0
AM-DSB-SC 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 99 560 0 0 0
FM 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 682 0 0
GMSK 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 662 0
OQPSK 0 0 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 647
OOK 4ASK 8ASK BPSK QPSK 8PSK 16PSK 32PSK 16APSK 32APSK 64APSK 128APSK 16QAM 32QAM 64QAM 128QAM 256QAM AM-SSB-WC AM-SSB-SC AM-DSB-WC AM-DSB-SC FM GMSK OQPSK
600
500
400
300
200
100
0

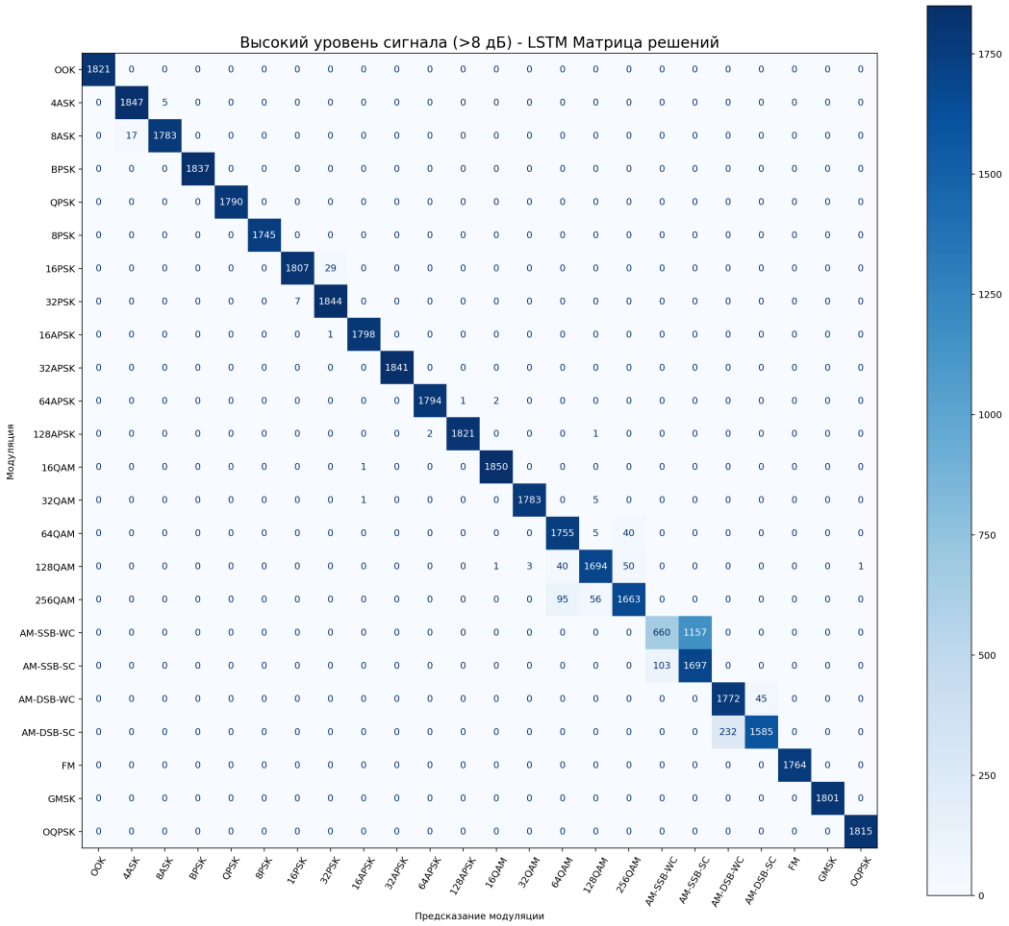
Высокий уровень сигнала (>8 дБ) - LSTM Матрица решений
Модуляция
Предсказание модуляции
OOK 4ASK 8ASK BPSK QPSK 8PSK 16PSK 32PSK 16APSK 32APSK 64APSK 128APSK 16QAM 32QAM 64QAM 128QAM 256QAM AM-SSB-WC AM-SSB-SC AM-DSB-WC AM-DSB-SC FM GMSK OQPSK
1750 1500 1250 1000 750 500 250 0

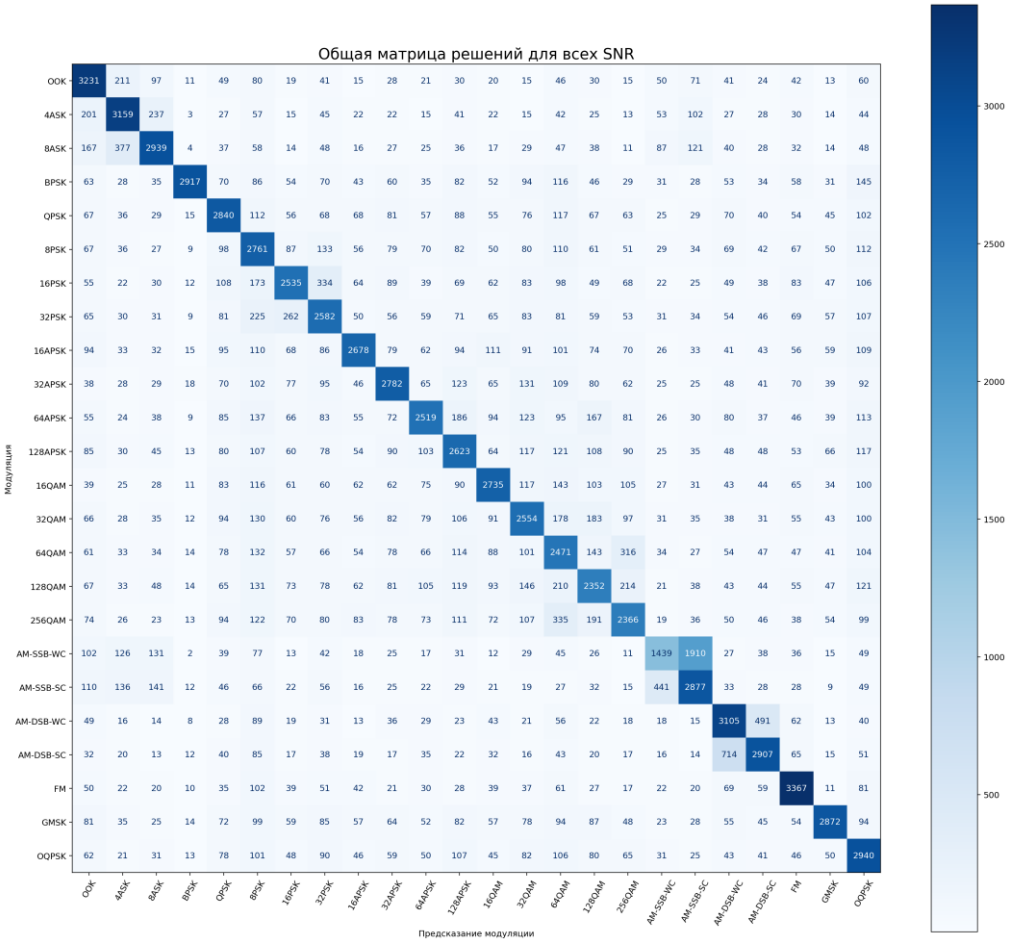
Общая матрица решений для всех SNR
Модуляция
Предсказание модуляции
OOK 4ASK 8ASK BPSK QPSK 8PSK 16PSK 32PSK 16APSK 32APSK 64APSK 128APSK 16QAM 32QAM 64QAM 128QAM 256QAM AM-SSB-WC AM-SSB-SC AM-DSB-WC AM-DSB-SC FM GMSK OQPSK
3000 2500 2000 1500 1000 500

4. Сравнения на 3 диапазонах

Далее приводится сравнение комбинированной модели, нейросетевые модели, классические алгоритмы машинного обучения на трех диапазонах.

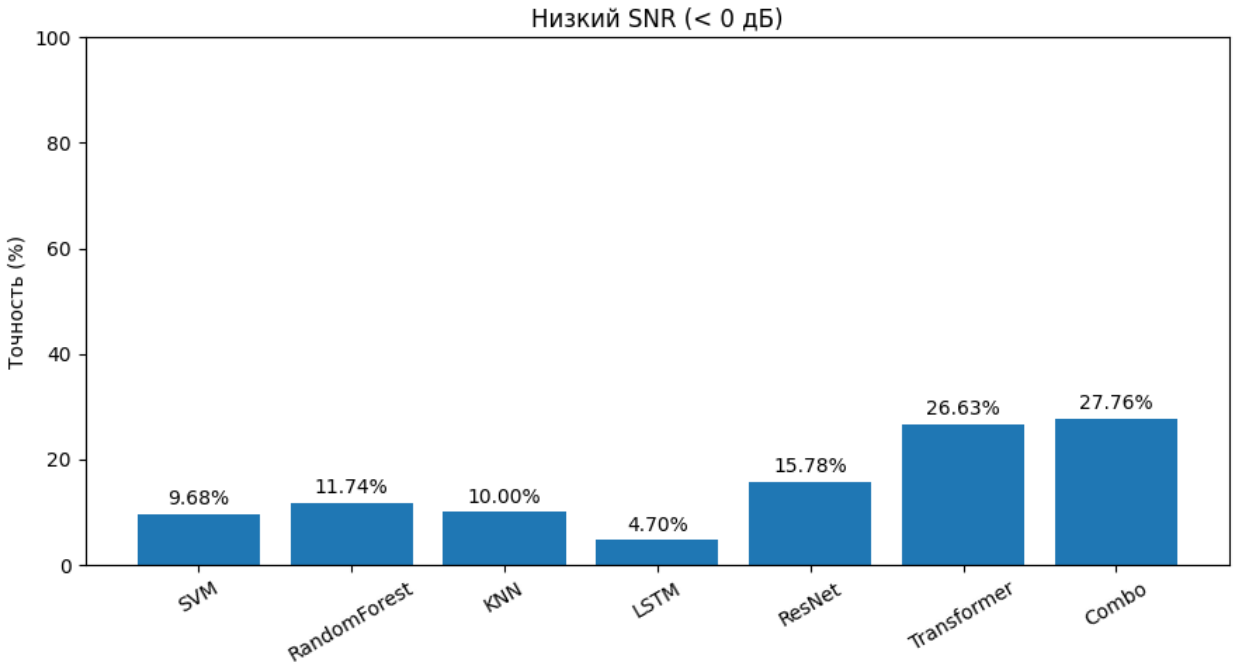

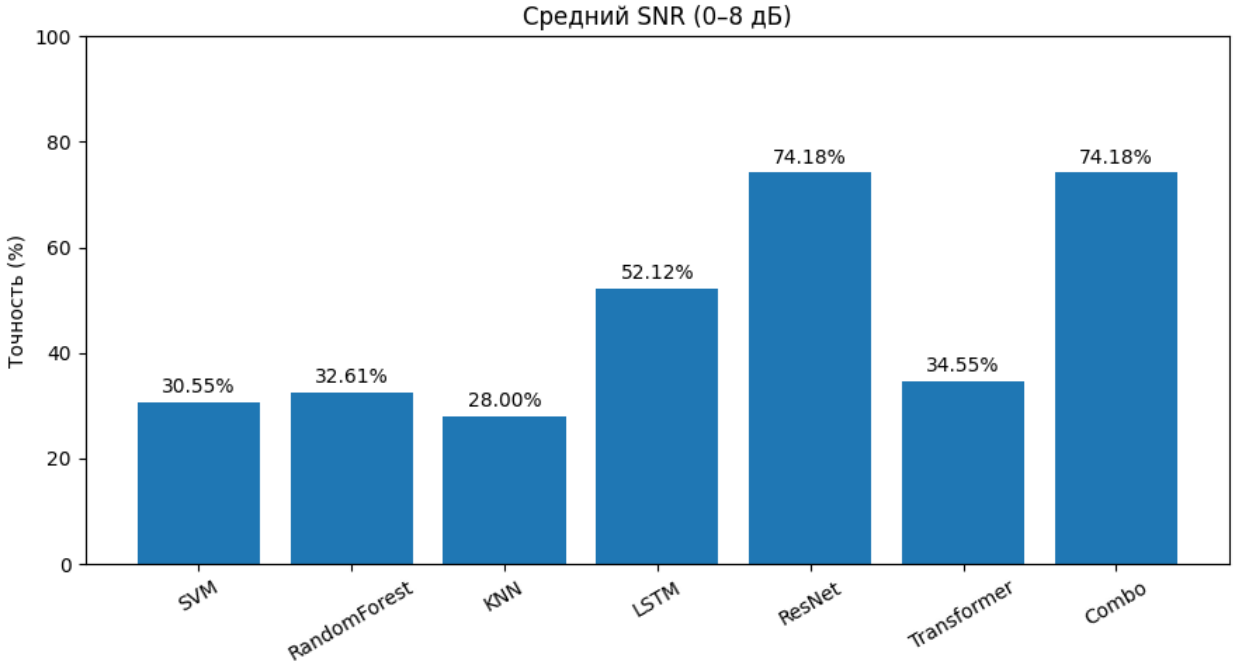

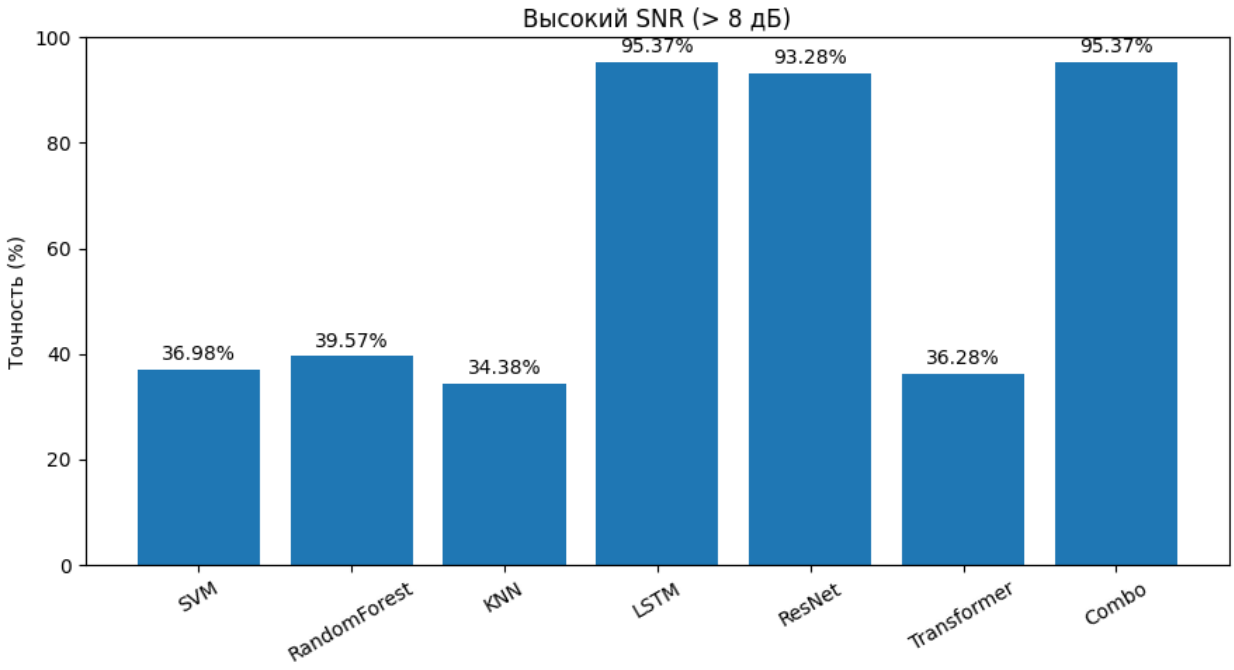

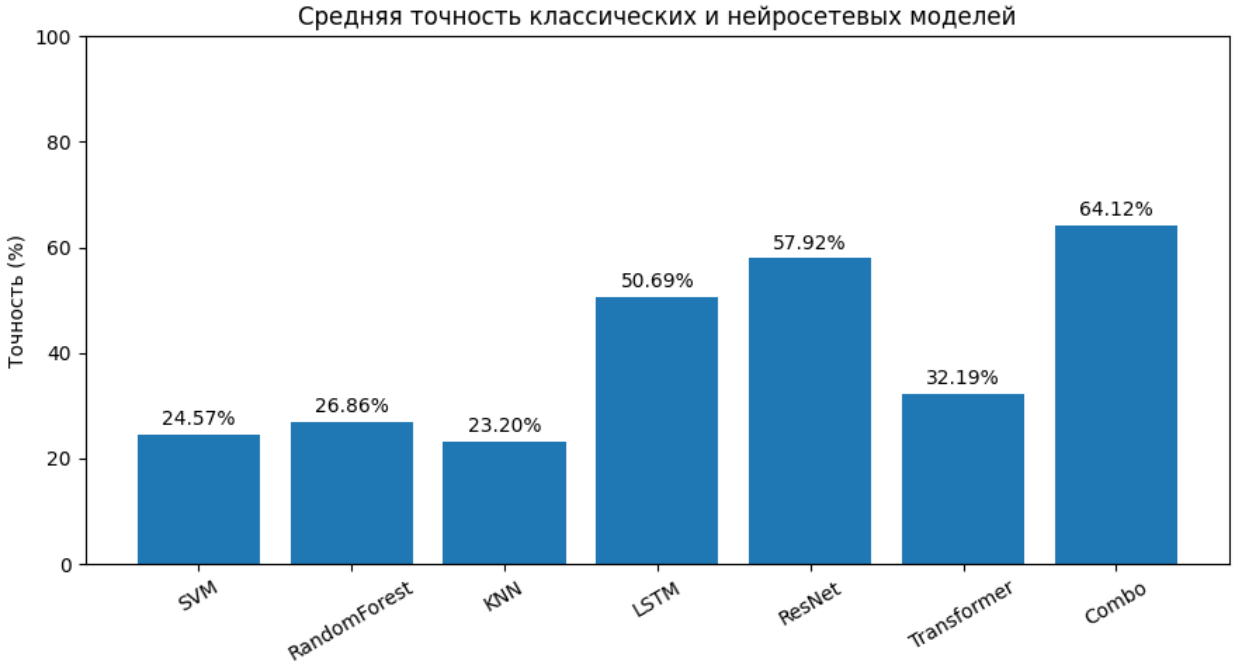

Таким образом, комбинирование трёх моделей позволяет достичь наилучших показателей точности, однако суммарный размер файлов достигает 73 МБ. В качестве альтернативы можно использовать только модель ResNet, что позволит значительно сэкономить место, при этом результаты останутся сопоставимыми.

5. Обучение модели распознавания ОСШ

Для создания адаптивного алгоритма распознавания потребовалась модель для предварительной оценки SNR, чтобы автоматически выбирать оптимальную нейросеть для классификации модуляции. Из-за ограничений вычислительных ресурсов обучение проводилось на каждом десятом отсчёт.

Для этой задачи была выбрана простая CNN-архитектура. Свёрточные сети эффективно выделяют энергетические и спектральные признаки сигнала, имеют меньше параметров для быстрого инференса и хорошо работают с одномерными данными, что обеспечивает баланс между точностью и производительностью.

Таким образом, CNN стала оптимальным компромиссом для вспомогательной модели SNR-оценки, потребляя минимум ресурсов при сохранении достаточной точности для корректного распределения сигналов между основными классификаторами: Transformer, ResNet, LSTM.

№	Блок	Состав блока	Назначение
1	Входной слой	I/Q-сигнал (2 × 1024)	Приём комплексного радиосигнала
2	Свёрточный блок 1	Conv1D (2→64) + BatchNorm + ReLU	Извлечение базовых временных и энергетических признаков
3	Свёрточный блок 2	Conv1D (64→128) + BatchNorm + ReLU	Углубление представления признаков
4	Подвыборка	MaxPool1D (×2)	Снижение временной размерности и подавление шума
5	Свёрточный блок 3	Conv1D (128→256) + BatchNorm + ReLU	Формирование высокоуровневых признаков
6	Агрегация по времени	AdaptiveAvgPool1D	Приведение признаков к фиксированной длине
7	Полносвязный блок	FC (256→128) + ReLU + Dropout	Регрессия и регуляризация
8	Выходной слой	FC (128→1)	Оценка значения SNR

В архитектуре модели SNR-CNN отдельные операции нормализации и активации объединены в свёрточные блоки, что позволяет компактно описывать структуру нейронной сети без потери информативности. Такой подход широко используется при представлении архитектур глубоких моделей в научных и выпускных квалификационных работах.

6. Устройство распознавания и декодирования радиосигналов

В рамках данной работы было разработано адаптивное устройство автоматического распознавания модуляции радиосигналов, основанное на использовании нейросетевых моделей. Архитектура устройства включает три нейронные сети, предназначенные для распознавания типа модуляции, а также отдельную нейронную сеть для предварительной оценки отношения сигнал/шум (ОСШ).

На первом этапе входной радиосигнал поступает в нейронную сеть оценки ОСШ, которая определяет уровень качества сигнала. На втором этапе, в зависимости от полученного значения ОСШ, осуществляется выбор наиболее подходящей нейросетевой модели классификации модуляции. Далее выбранная модель выполняет распознавание типа модуляции входного сигнала и формирует итоговый результат.

В ходе эксперимента было проведено испытание разработанной системы на основе датасета RadioML 2018. Для оценки работы алгоритма из общего массива данных была сформирована выборка из 10 000 случайных сигналов.

Для реализации данного подхода на вычислительное устройство предварительно загружаются обученные нейросетевые модели, включая модель регрессии SNR и набор моделей классификации модуляции, а также их архитектуры и веса. После инициализации моделей и переноса их в режим инференса входной I/Q-сигнал подаётся сначала на нейросеть оценки отношения сигнал/шум. Полученное значение SNR используется для выбора соответствующей модели распознавания модуляции, после чего сигнал

поступает на вход выбранной нейросети для окончательного определения типа модуляции.

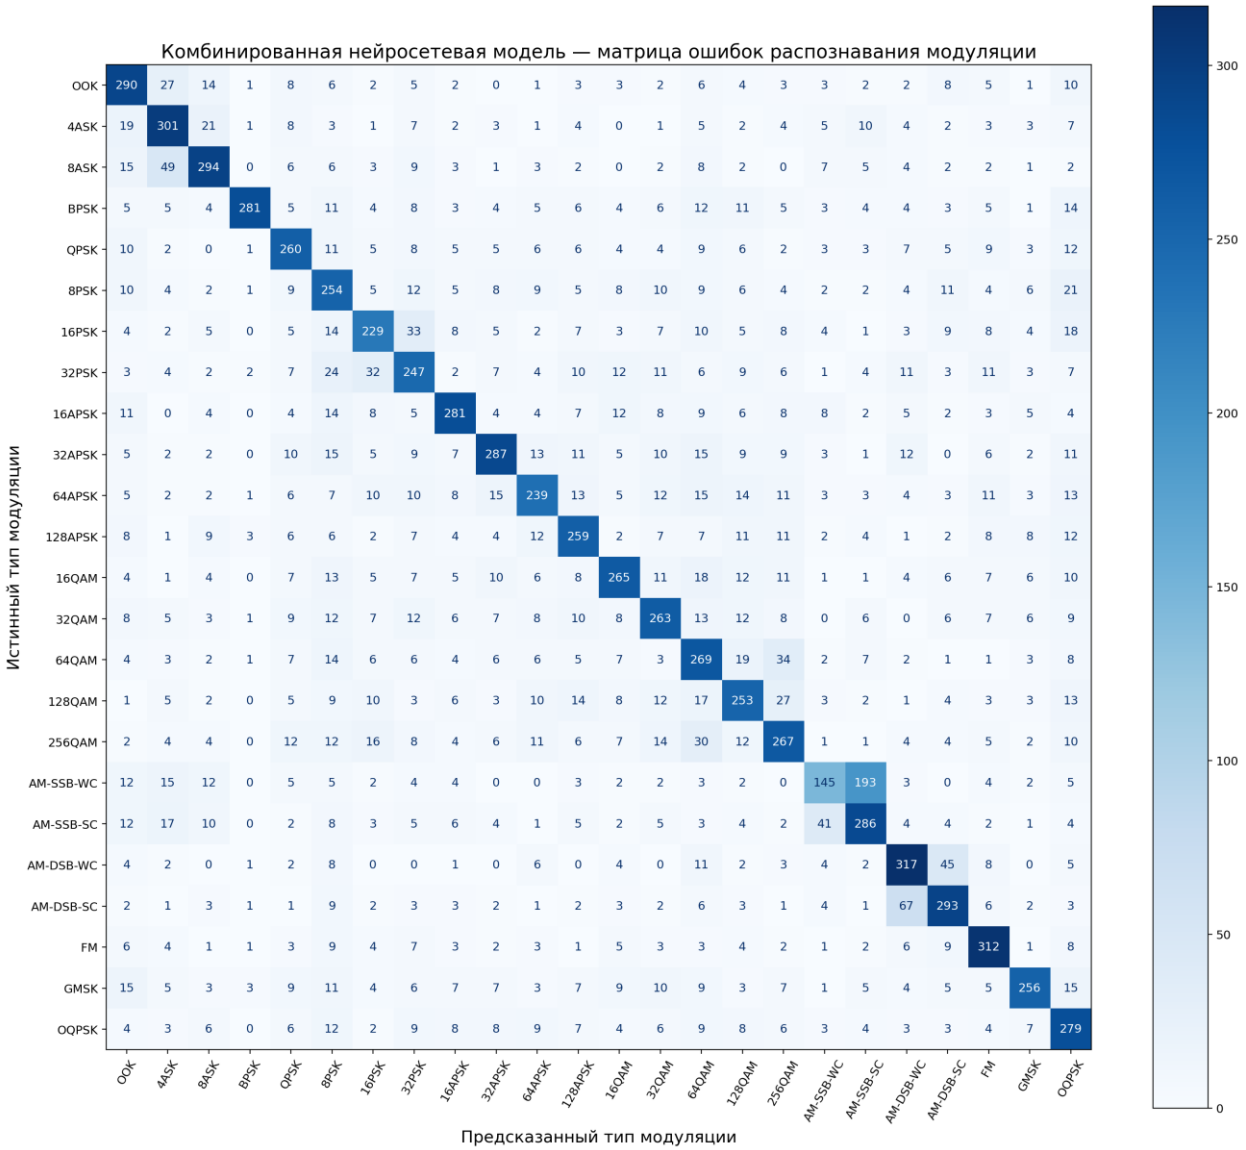

№	Истинная модуляция	Предсказанная модуляция	Реальный SNR, дБ	Оценённый SNR, дБ	Используемая модель
1	16QAM	16QAM	26.0	28.62	LSTM
2	16APSK	16APSK	0.0	-1.02	Transformer
3	256QAM	256QAM	22.0	21.79	LSTM
4	64APSK	64APSK	28.0	30.28	LSTM
5	16QAM	32APSK	-12.0	-15.94	Transformer
6	AM-DSB-SC	AM-DSB-SC	-2.0	-3.20	Transformer
7	16APSK	16APSK	28.0	30.29	LSTM

8	32PSK	32PSK	28.0	29.20	LSTM
9	128APSK	128APSK	20.0	20.08	LSTM
10	AM-DSB-SC	64APSK	-16.0	-11.86	Transformer
11	AM-SSB-WC	AM-SSB-WC	24.0	22.33	LSTM
12	8ASK	8ASK	-2.0	-4.55	Transformer
13	AM-SSB-SC	4ASK	-18.0	-15.00	Transformer
14	256QAM	32PSK	-6.0	-9.83	Transformer
15	8PSK	8PSK	12.0	10.71	LSTM
16	QPSK	QPSK	14.0	13.28	LSTM
17	4ASK	8PSK	-16.0	-13.01	Transformer
18	QPSK	QPSK	-18.0	-13.89	Transformer
19	128QAM	128QAM	4.0	3.12	ResNet
20	4ASK	4ASK	24.0	25.66	LSTM

7. Выводы и результаты работы

В ходе выполнения выпускной квалификационной работы была достигнута поставленная цель – разработано устройство (алгоритмическая модель) для распознавания и декодирования радиосигналов на основе методов машинного обучения.

Проведён анализ существующих методов распознавания радиосигналов. Были рассмотрены классические подходы цифровой обработки сигналов, а также современные нейросетевые методы, включая сверточные нейронные сети, рекуррентные сети и архитектуры типа Transformer. Показано, что нейросетевые методы обладают высокой устойчивостью к шуму и способны эффективно работать в условиях низкого отношения сигнал/шум.

Выбран и исследован современный датасет RadioML2018, который содержит синтетически сгенерированные радиосигналы различных типов модуляции, сформированные на основе математических моделей реальных

систем связи и искажённые аддитивным шумом при различных уровнях SNR. Это позволяет использовать его как приближение к реальным радиосигналам и применять для обучения и тестирования нейросетевых моделей.

Разработана нейросетевая модель оценки отношения сигнал/шум. С использованием библиотеки PyTorch была реализована сверточная нейронная сеть для регрессии SNR. Экспериментальные результаты показали, что модель способна с приемлемой точностью оценивать уровень SNR входного сигнала. Средняя ошибка оценки составила порядка 1–2 дБ, что является допустимым результатом для практических задач предварительного анализа сигнала.

Реализован комбинированный алгоритм распознавания сигналов. Предложен подход, при котором входной сигнал сначала подаётся на нейросеть оценки SNR, после чего в зависимости от полученного значения выбирается наиболее подходящая модель распознавания модуляции. Такой подход позволяет повысить общую точность распознавания по сравнению с использованием одной универсальной модели.

Проведены вычислительные эксперименты. Эксперименты проводились на выборке из 10 000 случайных примеров датасета RadioML2018. Для каждого сигнала последовательно выполнялась оценка SNR и классификация модуляции. Полученные результаты подтвердили работоспособность предложенной архитектуры и целесообразность адаптивного выбора модели.

Рассмотрен вопрос декодирования радиосигналов. Несмотря на то, что сигналы в датасете RadioML2018 являются синтетическими и не содержат реальной битовой информации, они соответствуют реальным видам модуляции. Это позволяет утверждать, что при подаче на разработанное устройство реального радиосигнала система способна не только распознать тип модуляции, но и выполнить его демодуляцию с использованием классических алгоритмов цифровой связи или дополнительных нейросетевых моделей.